한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

생성형 AI와 함께하는 파이썬 데이터 분석

코드를 짜는 사람이 아니라, AI에게 시키고 검증하는 사람

한국강사교육협회 이사 **전혜영**

한국강사교육협회 홈페이지
www.chatgpt1st.co.kr/

About the Instructor

한국강사교육협회 이사 **전혜영**

주요 경력

(現)한국강사교육협회 이사
(現)미래교육아카데미 전임강사
(現)배움더하기협동조합 이사
(前)킨더바움놀이교육센터 원장
(前)(주)디랩코드아카데미 동탄캠퍼스 코딩강사
(前)전북미래채움 강사양성과정 에듀코치 & 자격심사위원

자격 및 저서

챗GPT생성AI교육전문가
인공지능(AI)활용능력1급
프롬프트교육전문가1급
AI콘텐츠 크리에이터 지도사
메타버스교육지도사1급
인공지능교육지도사1급
기후변화교육전문가1급
3CT코딩강사(Scratch)
3D프린팅교육지도자
ITQ정보기술자격
소프트웨어코딩 지도사
Coding Specialist
Professional 2급
(Python)
AICE BASIK



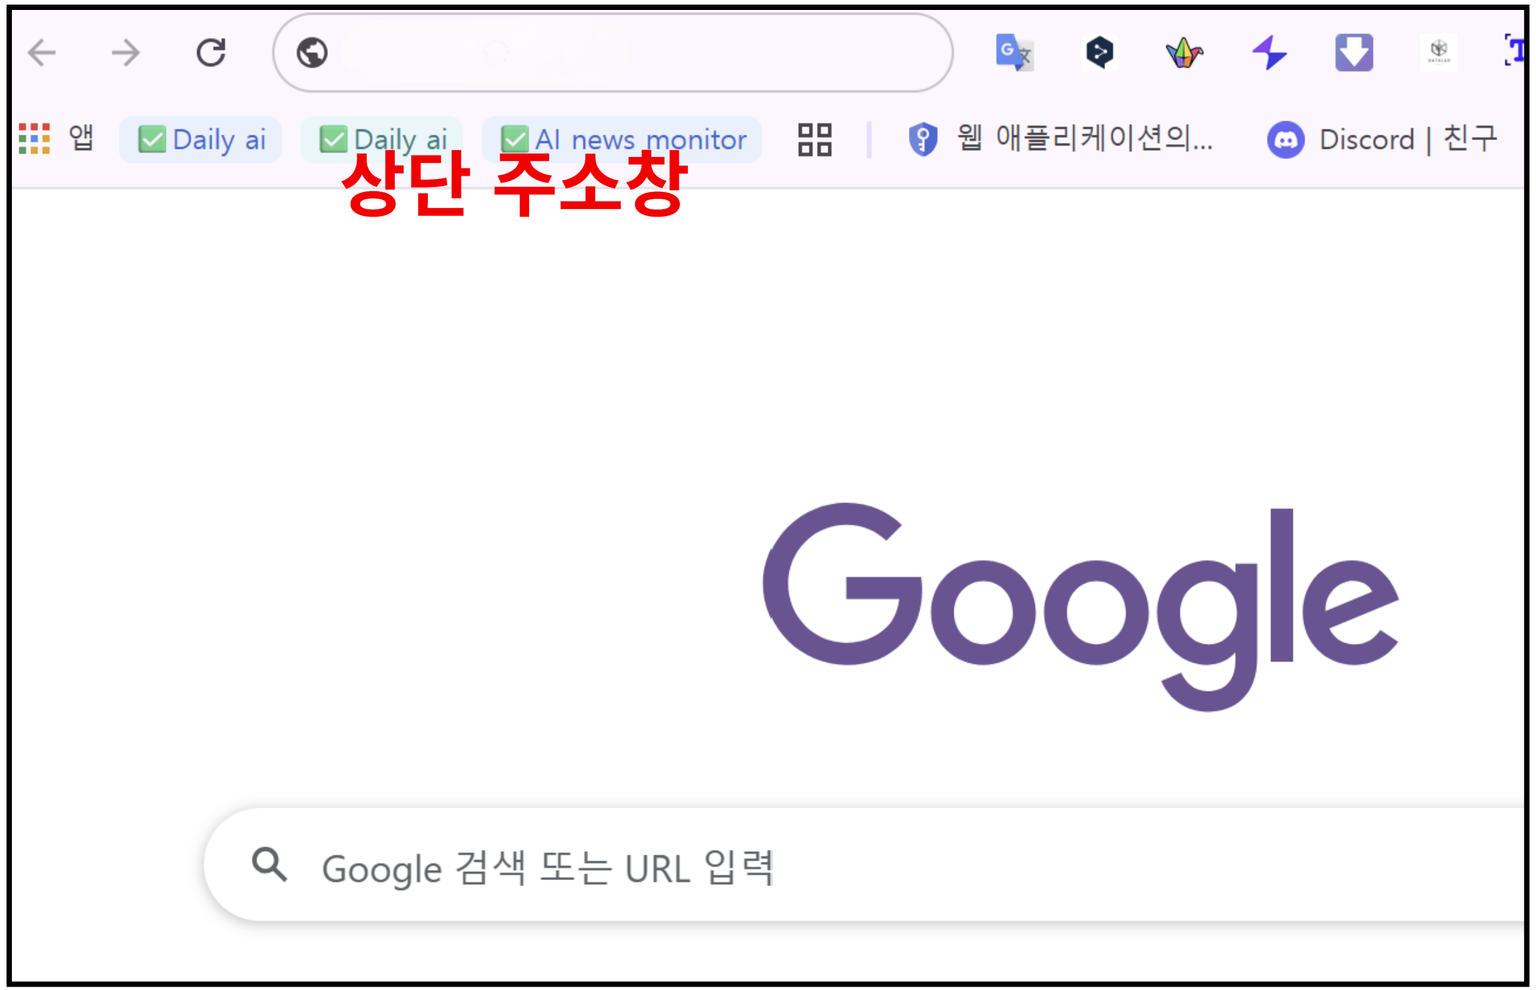
2024 챗GPT가 주도하는
AI 마케팅 가이드



주요 출강이력

- 한국동서발전 "[AI+] 생성형 AI 업무자동화 & 공공데이터 MCP 자동화" 강의
- 국립생물자원관 직무교육 "AI 비서와 함께하는 스마트 문서 실무" 강의
- 경상남도교육청 "교원 AI 디지털 맞춤형 수업역량강화 직무연수(중급)" Claude Pro 기반 업무자동화 실전 연수 강의
- 대학내일 "영업자를 위한 AI 활용법" 강의
- 강원특별자치도 소방학교 소방장·소방경 대상 "생성형 AI 활용 데이터 분석 및 업무자동화 실무" 강의
- 로우파트너스 소상공인 대상 "생성형 AI로 만드는 온라인 홍보·판로개척 콘텐츠" 강의
- 강진청년지원센터 청·중년 대상 "인공지능 활용능력 1급 자격증과정" 강의
- 청주여성새로일하기센터 사회복지사 경력단절 여성 대상 "챗GPT를 활용한 문서작성 기법" 강의
- 세종특별자치시청 임직원 대상 "AI활용 공공기관 업무 혁신과 실무 활용법" 강의
- 한국국제교류재단 "생성형 AI를 활용한 국제교류 업무 혁신과 효율화" 강의
- 강진청년지원센터 "인공지능 활용능력 1급 자격증과정" 강의
- 중앙전파관리소 AI기초개념 및 "국가 공공기관 AI보안 가이드북" 이해 강의
- 전남대학교농업생명과학대학 Agro-AI School 생성형AI활용 강의
- 경상국립대학교 2025년 조교역량강화워크숍 "생성형AI활용 업무효율화" 강의
- 대전창업성장캠퍼스 전략산업 ABCD+QR 역량강화 프로그램 "챗Gpt활용 업무효율화" , "챗Gpt활용 홍보 콘텐츠와 데이터 시각화까지 한번에!" 강의
- 중소상공인희망재단 "AI로 제품/메뉴 기획, 상세페이지 제작" 강의
- 2025년 104차 가족센터 종사자 공통역량강화교육 "문과생도 쉽게! ChatGPT와 파이썬 업무자동화(입문)" 강의(Zoom)
- 용인시공공형어린이집 연합회 직무교육"챗GPT활용 업무 효율화" 강의
- 시흥시노인복지관 장현카네이션센터 "제미나이와 생성형AI 첫걸음" 강의
- 부안군청 직원대상 "챗GPT 업무효율화 및 컨텐츠 제작" 강의
- 2024 인삼박물관 인삼대학 '중장년에게 필요한 챗GPT 및 실생활 활용' 강의
- 청주상공회의소 2024청년도전지원사업 '챗GPT와 생성형AI활용 영상 콘텐츠 제작' 강의
- 부천대학교 TBI프로그램 세무회계학과 입사지원서 특강 강의
- 철원군청 AI이용 환경조성 및 역량 강화를 위한 "철원군 Chat GPT 기초 교육" 교육지원
- 인천연수구청 인생이모작 지원센터 "인공지능의 이해와 챗GPT의 이해" 교육지원
- 삼성인재개발원 "24 삼성전기 T4 승격 교육" 팀빌딩 교육지원
- 2025 SSAFY삼성SW청년아카데미 아두이노 스마트시티 교육지원
- 화성시농업기술센터 생성형AI를 활용한 콘텐츠 제작 역량강화 교육지원
- 남서울대학교 직원 직무교육 <챗GPT와 생성형AI 활용 업무효율화> 교육지원
- 2024~2026 경기미래교육 양평캠퍼스 창의, 진로, 환경 프로그램 전임강사

bit.ly/1105파이썬



상단 주소창

목적지로 계속 클릭



Table of Contents

1 생성형 AI로 시작되는 파이썬 분석 혁신

2 데이터 분석을 위한 파이썬 이해

3 Python을 활용한 데이터 탐색 및 가공

4 Python을 활용한 데이터 분석

5 Python을 활용한 데이터 시각화

6 프로젝트 실습



시작하며

업무에서 엑셀로 가장 귀찮았던 반복작업은?



매일 같은 양식에
복사 · 붙여넣기

여러 라인의 파일을
하나로 합치기

불량률 계산 후
그래프 다시 그리기

오늘 배우는 내용은 이런 반복작업을 줄이는 첫걸음입니다

학습 목표

오늘의 목표: 시키고, 읽고, 검증하기



시킨다

프롬프트로 AI에게
분석 코드를 요청



읽는다

AI가 쓴 코드가
무엇을 하는지 이해



검증한다

결과가 업무 상식에
맞는지 확인

코드는 맞아도 분석은 틀릴 수 있다 → 그래서 읽고, 검증합니다

파이썬을 만든 사람 — 귀도 반 로섬



Guido van Rossum

누구? 네덜란드 출신 프로그래머 (1956년생)

언제? 1989년 말 만들기 시작 → 1991년 처음 공개

별명 BDFL — '자비로운 종신 독재자'
파이썬의 방향을 결정하던 역할 (2018년 내려놓음)

경력 구글 · 드롭박스 · 마이크로소프트에서 근무

크리스마스 휴가에 시작된 '취미 프로젝트'

1

1989년 크리스마스

다니던 암스테르담 연구소가
연휴로 문을 닫자
'일주일 동안 할 취미 거리'를
찾던 귀도

→

2

새 언어를 만들자

평소 구상하던
쉬운 프로그래밍 언어를
직접 만들기 시작
→ 1991년 세상에 공개

→

3

이름은 뱀이 아니다?

영국 코미디 TV 쇼
'몬티 파이썬의
날아다니는 서커스'의
팬이라 지은 이름

심심해서 만든 언어가 → 지금은 데이터 분석 · AI의 대표 언어

뱀 로고는 나중에 붙은 것 · 파이썬 공식 예제에는 코미디 쇼 대사인 'spam', 'eggs'가 자주 나옵니다

파이썬은 어떤 언어인가



영어 문장처럼 읽히는 쉬운 프로그래밍 언어

같은 일을 시켜도 — 화면에 Hello 출력하기

```java
public class Main {
  public static void main(String[] a) {
    System.out.println("Hello");
  }
}
```

Java : 5줄

```python
print("Hello")
```

Python : 1줄

무료 · 오픈소스 · 데이터 분석 · AI · 업무 자동화 · 웹 서비스까지 두루 쓰임

파이썬의 장점과 단점

장점

- 문법이 쉽고 짧아 처음 배우기 좋다
- pandas · 그래프 · AI 도구가 이미 다 만들어져 있다
- 무료이고, 사용자가 많아 자료와 AI 답변이 풍부하다
- 엑셀 반복 작업 자동화에 바로 쓸 수 있다

단점

- C · Java보다 실행 속도가 느린 편

데이터 분석 도구는 내부를 빠르게 만들어 체감은 적음

- 들여쓰기(띄어쓰기)를 틀리면 오류가 난다
- 스마트폰 앱 · 게임 개발에는 덜 쓰인다

오늘의 목적(데이터 분석 · 업무 자동화)에는 장점이 훨씬 크다

예시 데이터

오늘의 예시 데이터: A라인 설비 센서 로그

일시	설비ID	온도	압력	생산량	불량여부
2026-03-02 08:00	A-01	65.2	1.2	120	0
2026-03-02 09:00	A-01	66.0	1.3	118	0
2026-03-02 10:00	A-02	82.4	1.9	95	1
2026-03-02 11:00	B-01		1.1	0	0

※ 가상 데이터 · 온도(℃) · 압력(bar) · 불량여부: 1 = 불량, 0 = 정상

빈 칸과 0이 섞인 4번째 행은 3모듈에서 다시 만납니다

제조 데이터로 배우지만, 방법은 내 업무에 그대로

제조 · 품질

검사값 · 규격 · 불량
설비 온도 · 생산량

→ 오늘 실습 그대로

IT · 솔루션

고객사 MES · QMS 데이터
시스템 로그 · 장애 건수

→ 같은 방법으로
집계 · 이상 구간 찾기

컨설팅 · 공공

업무량 · 처리 시간
만족도 설문 · 공공 통계

→ 비율 · 평균의 함정
그룹 비교 · 보고서

데이터만 바뀔 뿐 → 불러오기 · 확인 · 묶기 · 그래프 · 검증은 같다

6모듈 프로젝트에서는 내 업무 데이터(가명 처리)나 공공데이터로 해도 됩니다

파이썬을 실행하는 두 가지 방법

VS Code

내 컴퓨터에 설치하는 프로그램

· Python · VS Code 설치 필요
· 파일이 내 PC 폴더에 저장
· 회사 실무에서 많이 사용
· 설치 권한이 필요할 수 있음

Google Colab

브라우저에서 바로 쓰는 노트북

· 설치 없음 (구글 계정만)
· 분석 도구가 이미 설치됨
· 셀 단위로 실행 · 결과가 바로 아래
· 파일은 세션이 끝나면 사라짐

파이썬 코드는 똑같습니다 → 다른 것은 '실행하는 곳'뿐

오늘은 Google Colab으로 진행합니다

1

설치 없이 바로

교육장 PC 설치 권한·
버전 문제 없이
첫 시간부터 실습

2

도구가 다 있다

pandas · scikit-learn ·
seaborn · plotly가
이미 설치되어 있음

3

결과가 바로 보인다

셀을 실행하면
표와 그래프가
바로 아래에

회사에서 계속 쓰려면 → 부록 'VS Code로 실습하려면'을 참고하세요 (코드는 그대로 사용)

Colab 시작하기 — 네 단계

1

접속

크롬에서
colab.research.google.com
→ 구글 로그인

→

2

노트북 열기

[파일] → [노트북 업로드]
실습노트북_Colab_
1-6모듈.ipynb

→

3

데이터 올리기

왼쪽 📁 아이콘
→ 엑셀 2개 · CSV
끌어다 놓기

→

4

폰트 셀 실행

【준비】 셀 클릭
→ Shift + Enter
→ '설정 완료'

셀 실행 = Shift + Enter · 오류가 나면 메시지를 ChatGPT에 붙여넣고 "고쳐줘"

【준비】 한글 폰트 설정 — 실행 결과

[1]

```
# 【준비】 한글 폰트 설치 (Colab · 처음 한 번만)
! sudo apt-get -qq -y install fonts-nanum
import matplotlib.font_manager as fm
import matplotlib.pyplot as plt
fm._load_fontmanager(try_read_cache=False)
plt.rcParams['font.family'] = 'NanumGothic'
plt.rcParams['axes.unicode_minus'] = False
print('한글 폰트 설정 완료')
```

```
한글 폰트 설정 완료
```

'한글 폰트 설정 완료'가 나오면 준비 끝 · 그래프 한글이 깨지면 세션 다시 시작 후 다시 실행

Colab 자주 쓰는 단축키와 유의사항

기능	단축키
셀 실행 + 다음 셀로	Shift + Enter
현재 셀만 실행	Ctrl + Enter
아래에 코드 셀 추가	Ctrl + M → B
실행 중지	Ctrl + M → I

꼭 기억할 3가지

① 90분 동안 실행이 없으면 연결이 끊김
② 끊기면 올린 파일이 사라짐 → 다시 올리기
③ 결과 파일은 그때그때 내려받기

끊겼을 때 : [런타임] → [세션 다시 시작]
→ 파일 다시 올리기 → 【준비】 셀부터

쉬는 시간에도 셀을 한 번씩 실행해 두면 연결이 유지됩니다

Colab에서 이런 것도 됩니다 — 새로운 기능 4가지

시각화 모드 + 전체 화면 공유

★ 오늘 실습 ⑧-2

말로 주문하면 Gemini가 코드를 만들고
실행·오류 수정까지 해서 대시보드 완성
결과만 링크 하나로 공유

Colab CLI

개발자용

내 컴퓨터 '터미널'에서 명령어로
Colab의 GPU를 빌려 코드 실행
(colab exec 내파일.py)

Colab MCP 서버

AI 에이전트용

Claude Code 같은 AI 에이전트가
Colab 노트북에 직접 셀을 만들고
코드를 실행

G4 GPU 지원

유료 (Pro+)

NVIDIA RTX PRO 6000 Blackwell
고성능 GPU (Colab Pro+ 구독자)
큰 AI 모델 학습·실행용

Colab 첫 화면 '새로운 기능' 안내 · 출처 : Google 공식 블로그 (2026년 3~6월 발표)

오늘 우리가 쓸 것 : 말로 주문하는 '시각화 모드'

1

Gemini 메뉴

Gemini 창 입력칸
⚙(조절) 아이콘
→ 시각화 모드

→

2

말로 주문

"df로 공정 품질
대시보드 만들어줘"

→

3

알아서 완성

코드 작성 → 실행 →
오류 나면 스스로 수정
→ 대화형 그래프

→

4

링크로 공유

출력 메뉴 →
전체 화면 출력 링크
코드 없이 결과만

ChatGPT ↔ Colab 복사·붙여넣기 없이, Colab 안에서 한 번에

공유 링크는 노트북의 Google Drive 공유 권한을 그대로 따릅니다 (노트북을 볼 수 있는 사람만 열람)

1

생성형 AI로 시작되는 파이썬 분석 혁신

분석 워크플로우 · 3대 라이브러리 · 코드 읽기 기초

파이썬은 컴퓨터에게 '일을 시키는' 언어

데이터를 계산하기 위한 언어라기보다, 데이터와 관련된 일을 시키기 위한 언어

읽어라	찾아라	골라라
바꿔라	**묶어라**	**계산해라**
비교해라	그려라	저장해라

```
df.groupby("설비ID")["생산량"].mean()
```

= 설비별로 묶어서 → 생산량 평균을 계산해라

데이터 분석은 8단계로 흘러갑니다

1. **데이터를 가져온다** — 로딩
2. **데이터가 어떻게 생겼는지 본다** — 탐색
3. **필요한 것만 골라낸다** — 전처리
4. **잘못된 데이터를 고친다** — 전처리
5. **계산한다** — 변환
6. **그룹으로 나눈다** — 변환
7. **그래프로 본다** — 시각화
8. **의미를 해석한다** — 사람의 몫

Python은 이 과정을 컴퓨터에게 시키는 수단입니다

엑셀과 파이썬, 언제 무엇을 쓸까

엑셀		파이썬
작은 데이터 (시트당 약 104만 행까지)	데이터 크기	수백만 행도 처리
매번 손으로 다시	반복 작업	한 번 만들고 실행만
클릭한 과정이 남지 않음	과정 기록	코드에 모든 과정이 남음
눈으로 보며 조금 고치기	어울리는 일	여러 파일 합치기 · 자동화

작고 한 번이면 엑셀 · 많고 반복되면 파이썬

파이썬, 일단 한 번 실행해 봅시다

강사 시연

① 글자 보여주기

```
print("A라인 데이터 분석 시작")
```

실행 결과
A라인 데이터 분석 시작

② 담고 → 보여주기

```
temperature = 65.2
print(temperature)
```

실행 결과
65.2

print()는 화면에 보여줘 **=은 오른쪽 값을 왼쪽 이름에 담아줘**

문법 암기에서 '읽고 검증하기'로

과거

문법 암기 → 코드 작성 → 결과

생성형 AI 시대

문제 이해 → **AI에게 요청** → **코드 생성** → **의미 파악** → **결과 검증** → **수정**

진한 칸 = AI가 대신할 수 없는 사람의 몫

핵심 질문: "이 코드가 무엇을 시키고 있는가?"

좋은 프롬프트의 4요소

1 역할

"너는 제조 데이터 분석을 돕는 파이썬 전문가야"

2 데이터 설명

"열은 일시, 설비ID, 온도, 압력, 생산량, 불량여부"

3 목표

"시간대별 불량률을 알고 싶어"

4 출력 형식

"Colab에서 실행할 거야. 결과는 print()로 보여줘"

완성된 프롬프트

너는 제조 데이터 분석을 돕는 파이썬 전문가야. A라인_센서로그.csv 파일은 일시, 설비ID, 온도, 압력, 생산량, 불량여부 열로 되어 있어. 시간대별 불량률을 알고 싶어. Google Colab에서 실행할 거야. 결과는 print()로 보여주고, 각 줄에 한국어 주석을 달아줘.

ChatGPT로 첫 그래프 받기 — 5분

1 → **2** → **3** → **4**

1 ChatGPT에 주문

다음 슬라이드의
프롬프트 붙여넣기
→ 전송

2 코드 복사

답변 코드 상자
오른쪽 위
[코드 복사]

3 Colab에 붙여넣기

[+ 코드] 새 셀
→ Ctrl + V
→ Shift + Enter

4 그래프 완성!

목표선 · 색깔 ·
숫자가 들어간
막대그래프

데이터 파일 없이, 숫자 4개만 말해도 그래프가 나온다

방금 배운 4요소 : 역할(Colab 코드) · 데이터(라인별 생산량) · 목표(목표 미달 찾기) · 출력 형식(막대·색·한글)

라인별 오늘 생산량 그래프 주문하기

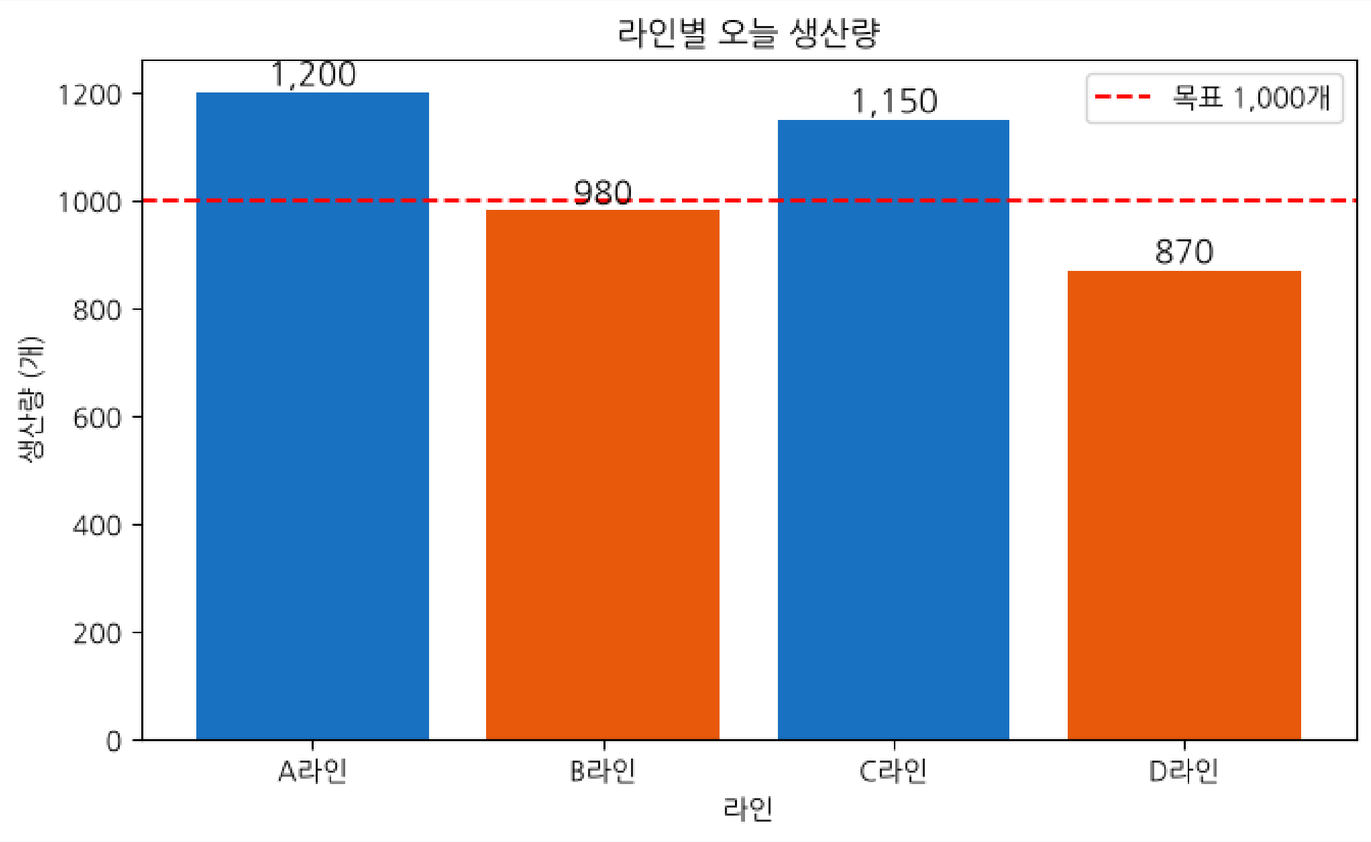
ChatGPT에게 이렇게 시키기

Colab에서 실행할 파이썬 코드를 짜줘. A·B·C·D 라인의 오늘 생산량이 1200, 980, 1150, 870개야. 막대그래프로 그리고, 목표 1000개에 빨간 점선을 그어줘. 목표를 넘은 라인은 파란색, 못 넘은 라인은 주황색으로 칠하고 막대 위에 숫자를 써줘. 제목과 축 이름은 한글로.

목표선 아래 주황 막대 2개(B · D라인)가 보이면 성공

더 해보기 : "가로 막대로 바꿔줘" · "E라인 1,050개도 추가해줘"

라인별 오늘 생산량 — 실행 결과



목표 1,000개 미달 = B라인 980 · D라인 870 (주황) · 노트북 대체 셀 : 【미니①】

코드 한 줄 해부하기: 왼쪽에서 오른쪽으로

```
df["온도"].mean()
```

df

표 (이름표)

DataFrame에 붙인 이름
엑셀 시트 한 장

["온도"]

열 고르기

대괄호 = 고르기
엑셀에서 온도 열 클릭

.mean()

할 일 시키기

점 = ~의 기능, 괄호 = 실행
엑셀의 AVERAGE 함수

= 표에서 온도 열을 골라 평균을 내라

같은 방식으로: **df.groupby("설비ID")["생산량"].sum()** → 표를 설비ID로 묶고 → 생산량 열의 → 합계

주석과 변수: # 와 = 만 알아도 절반은 읽힌다

```
# 오늘 A라인 생산량
production = 1200
```

#

주석

뒤의 글은 실행되지 않는 메모
AI 코드의 주석 = 친절한 해설

=

변수

오른쪽 값을 왼쪽 이름표에 담기
production 상자에 1200을 넣음

공장에 비유하면: 언어 하나, 설비 여러 대

Python = 공장을 움직이는 작업 언어

계산 장비

NumPy

숫자를 빠르게 계산

```
import numpy as np
```

작업대

Pandas

표 데이터를 다루는 곳

```
import pandas as pd
```

모니터

Matplotlib

결과를 그래프로 보여줌

```
import matplotlib.pyplot as plt
```

더 알아두면 좋은 설비

Seaborn · 고급 모니터

Scikit-learn · 자동화 설비 (머신러닝)

생성형 AI · 작업 도우미

라이브러리 = 공장에 들여놓는 설비 · import = 설비를 가져와 켜기

NumPy: 많은 숫자를 빠르게 계산하는 도구

```
import numpy as np
temps = np.array([65.2, 66.0, 82.4])
```

`np.mean(temps)`

평균

→ **71.2**

`np.max(temps)`

최댓값

→ **82.4**

`np.min(temps)`

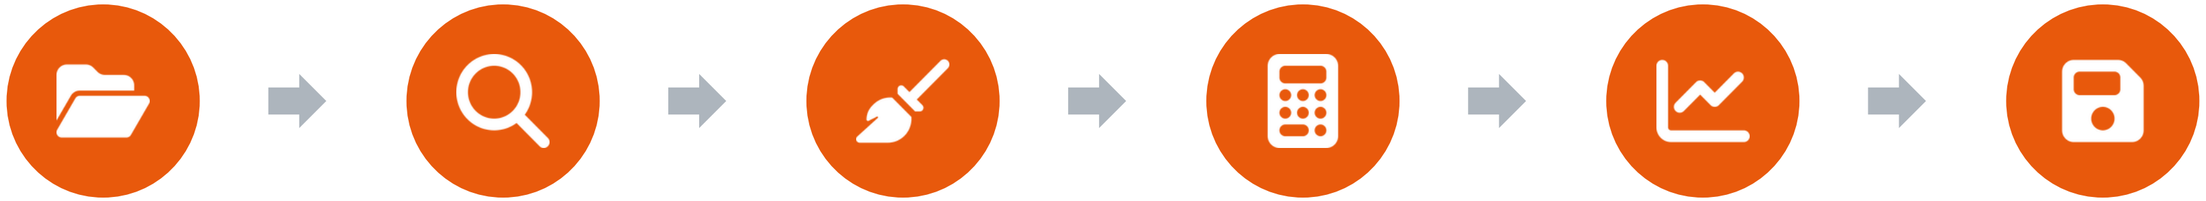
최솟값

→ **65.2**

np.array = 숫자 묶음 만들기 · Pandas 안에서도 NumPy가 계산을 맡습니다

이번 과정은 NumPy를 직접 쓰기보다 Pandas 중심으로 분석합니다

데이터 분석의 기본 패턴: 6단계



① 로딩	② 탐색	③ 전처리	④ 변환	⑤ 시각화	⑥ 저장
불러오기	들여다보기	고치기	계산·묶기	그래프	파일로 남기기
센서로그 파일 열기	행·열 개수 빈 값 확인	빈 날짜 채우기	설비별 생산량 합계	온도 추이 그래프	결과를 CSV로 저장

단계별 주요 기법은 2모듈에서 AI 실습 직전에 자세히 봅니다

6단계 기본 패턴 한 장 정리

단계	확인 질문	대표 코드	엑셀로 치면
① 로딩	다 불러왔나?	df = pd.read_excel("파일.xlsx")	파일 열기
② 탐색	어떻게 생겼나?	df.describe()	상태 표시줄 요약
③ 전처리	계산할 수 있나?	df["날짜"].ffill()	빈칸 채우기
④ 변환	질문에 답하나?	df.groupby("설비ID")["생산량"].sum()	피벗테이블
⑤ 시각화	한눈에 보이나?	df["온도"].plot()	차트 삽입
⑥ 저장	다시 쓸 수 있나?	df.to_csv("결과.csv", encoding="utf-8-sig")	다른 이름으로 저장

외우지 않아도 됩니다. 각 줄이 '어느 단계인지'만 알아보면 됩니다

분석 후 무조건 확인하는 3가지

① 건수

원본 10,000행 → 결과 7,321행
→ 2,679행은 왜 사라졌지?

② 합계

엑셀 생산량 합계 125,300
= 파이썬 생산량 합계 125,300?

③ 상식

온도 최댓값 9,999℃
→ 분석 결과가 아니라
데이터 오류 의심

코드는 맞아도 분석은 틀릴 수 있다 → 건수 · 합계 · 상식

이 코드는 무엇을 하는 코드일까요?

```
df = pd.read_csv("A라인_센서로그.csv")
df = df.dropna()
print(df.groupby("설비ID")["불량여부"].mean())
```



1번째 줄은 어느 단계?



2번째 줄은 어느 단계?



3번째 줄은 어느 단계?

힌트: 불량여부는 1 = 불량, 0 = 정상 → 평균을 내면?

2

데이터 분석을 위한 파이썬 이해

데이터 수집 · 저장 · 관리의 기본 원칙 · 실습 환경 미리보기

데이터는 어디에서 오는가

현장 데이터

MES 생산실적
설비 센서 로그
품질검사 기록(엑셀)

공공 데이터

공공데이터포털 등
기관이 공개한 통계·현황
대부분 CSV·엑셀로 제공

웹 데이터

웹페이지의 표·글 수집
수집 전 이용약관 확인
자동 수집은 심화 과정

데이터를 받을 때 '어디서 왔는지(출처)'를 함께 기록하는 것이 관리의 시작입니다

CSV · XLSX · JSON, 무엇이 다른가



CSV

쉼표로 구분된 순수 텍스트
가볍고 어디서나 열림
→ 분석에 가장 편리

pd.read_csv()



XLSX

엑셀 파일
서식 · 여러 시트 포함
→ 읽을 시트 지정 필요

pd.read_excel()



JSON

{ 이름: 값 } 구조의 데이터
웹 · 시스템 연동에 주로 사용

pd.read_json()

사람이 보기 좋은 표 vs 분석하기 좋은 표

× 사람이 보기 좋은 표

3월 생산실적		
구분	**3월 1일**	**3월 2일**
A라인	1,200	1,150(재측정)
B라인	980	미입력

병합 셀

색으로만 표시

숫자 + 메모 섞임

날짜가 열 제목

○ 분석하기 좋은 표

날짜	라인	생산량	비고
03-01	A	1200	
03-02	A	1150	재측정
03-01	B	980	
03-02	B		미입력

한 행 = 한 기록 · 한 열 = 한 항목

빈 값은 빈칸으로, 설명은 비고 열로

원본 보존 · 파일명 규칙 · 경로

원본은 그대로

원본은 따로 보관하고
사본으로 작업

파일명 규칙

날짜_라인_내용.csv
한눈에 알아보는 이름

경로 알기

경로 = 파일의 주소
파일이 '어디에' 있는지

추천 폴더 구조: 분석프로젝트/

원본/
손대지 않음

→

작업/
정리·가공한 사본

→

결과/
그래프·보고서

예) 원본/20261004_A라인_센서로그.csv

한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

AI에 데이터를 올리기 전, 세 번 확인



1

회사 정책

사내 보안 규정과
AI 사용 지침을 먼저 확인

2

개인정보

이름 · 사번 · 연락처는
지우거나 가리기

3

영업 비밀

고객사명 · 공정 조건 · 수율 등은
가명 처리 또는 제외

TIP 데이터 전체 대신 '열 이름 + 가짜 샘플 몇 줄'만 주고 코드를 받은 뒤,
받은 코드를 실제 데이터에 적용하기

파일을 표(df)로 불러오기

목적: 파일을 열어 파이썬의 표(df)로 만든다

```
pd.read_csv("파일.csv")
```

CSV 파일 읽기

엑셀로 치면: CSV 파일 열기

```
pd.read_excel("파일.xlsx")
```

엑셀 파일 읽기

엑셀로 치면: 엑셀 파일 열기

```
# 위에 제목 줄? 시트 여러 개?
```

구조를 AI에게 알려주기

엑셀로 치면: 제목 줄 건너뛰고 표만 보기

제목·규격 줄이나 시트가 여러 개면 → "데이터는 4행부터, 시트 9개를 합쳐줘"처럼 AI에게 알려주기

확인 포인트 · print(df.shape)로 본 행·열 개수가 원본과 같은가?

데이터와 먼저 인사하기

목적: 분석하기 전에 데이터의 생김새를 확인한다

df.head()	df.dtypes	df.describe()	df.isnull().sum()
앞 5줄 보기	**열별 자료형**	**평균 · 최소 · 최대**	**빈 칸 개수**
엑셀로 치면: 화면 위쪽 훑어보기	엑셀로 치면: 셀 서식(숫자/텍스트)	엑셀로 치면: 상태 표시줄 요약	엑셀로 치면: 이동 옵션 → 빈 셀

파일을 읽었다 ≠ 분석 준비 끝 → "1,200" · "3.5kg" · "-"처럼 숫자로 보이는 글자를 dtypes로 확인

확인 포인트 · 숫자 열에 글자가 섞이지 않았나? 최솟값 · 최댓값이 상식 범위인가?

분석할 수 있는 상태로 고치기

목적: 빈 칸 · 잘못된 형식을 고쳐 계산할 수 있게 만든다

```
df["날짜"] = df["날짜"].ffill()
```

빈 칸을 위 값으로 채우기

엑셀로 치면: 병합 해제 후 위 값 복사

```
df = df.dropna()
```

빈 값이 있는 행 지우기

엑셀로 치면: 빈 행 삭제

```
df = df.fillna(0)
```

빈 칸을 정한 값으로 채우기

엑셀로 치면: 빈 셀 선택 후 한 번에 입력

⚠ dropna()는 행을 실제로 지웁니다 → 지우기 전에 '왜 비었는지' 먼저 확인 (고장 시간일 수도)

확인 포인트 · 처리 전과 후의 행 수 · 빈 값 수를 비교했나?

질문에 답하는 형태로 바꾸기

목적: 필요한 것만 고르고, 새로 계산하고, 묶어서 집계한다

```
df[df["온도"] >= 80]
```

조건에 맞는 행 고르기

엑셀로 치면: 필터

```
df["고온"] = df["온도"] >= 80
```

새 열 만들기

엑셀로 치면: 수식 열 추가 (=IF)

```
df.groupby("설비ID").sum()
```

그룹별로 묶어 계산

엑셀로 치면: 피벗테이블 · 부분합

여러 표를 합치는 방법(concat · merge)은 3모듈 '가공 4대 기술'에서 다룹니다

확인 포인트 · 건수 · 합계가 엑셀로 계산한 값과 같은가?

목적에 맞는 그래프 고르기

목적: 숫자를 한눈에 보이게 만든다 · 먼저 '무엇을 보고 싶은지'를 정한다

`df["온도"].plot()`

추세 → 선 그래프

엑셀로 치면: 꺾은선형 차트

`.plot(kind="bar")`

비교 → 막대 그래프

엑셀로 치면: 세로 막대형 차트

`.plot(kind="hist")`

분포 → 히스토그램

엑셀로 치면: 히스토그램 차트

`.plot(kind="scatter")`

관계 → 산점도

엑셀로 치면: 분산형 차트

한글 깨짐 방지 【준비】 셀 실행 (Colab : NanumGothic) · 그래프는 셀 마지막 줄에 plt.show()

확인 포인트 · 제목 · 축 단위가 있고, 목적에 맞는 그래프인가?

파일을 올리고, 한 번에 그래프까지

1

로딩

가상 센서로그 CSV
2,400행
(📁 패널에 올리기)

→

2

변환

설비 ID별
불량률(%) ·
평균 온도 계산

→

3

시각화

막대그래프 2개
가장 나쁜 설비는
빨간색

2모듈에서 배운 분석 단계 ① 로딩 → ④ 변환 → ⑤ 시각화를 한 번에

연습용 가상 데이터 (설비 5대 · 1시간 단위 · 불량여부 1 = 불량)

설비별 불량률 그래프 주문하기

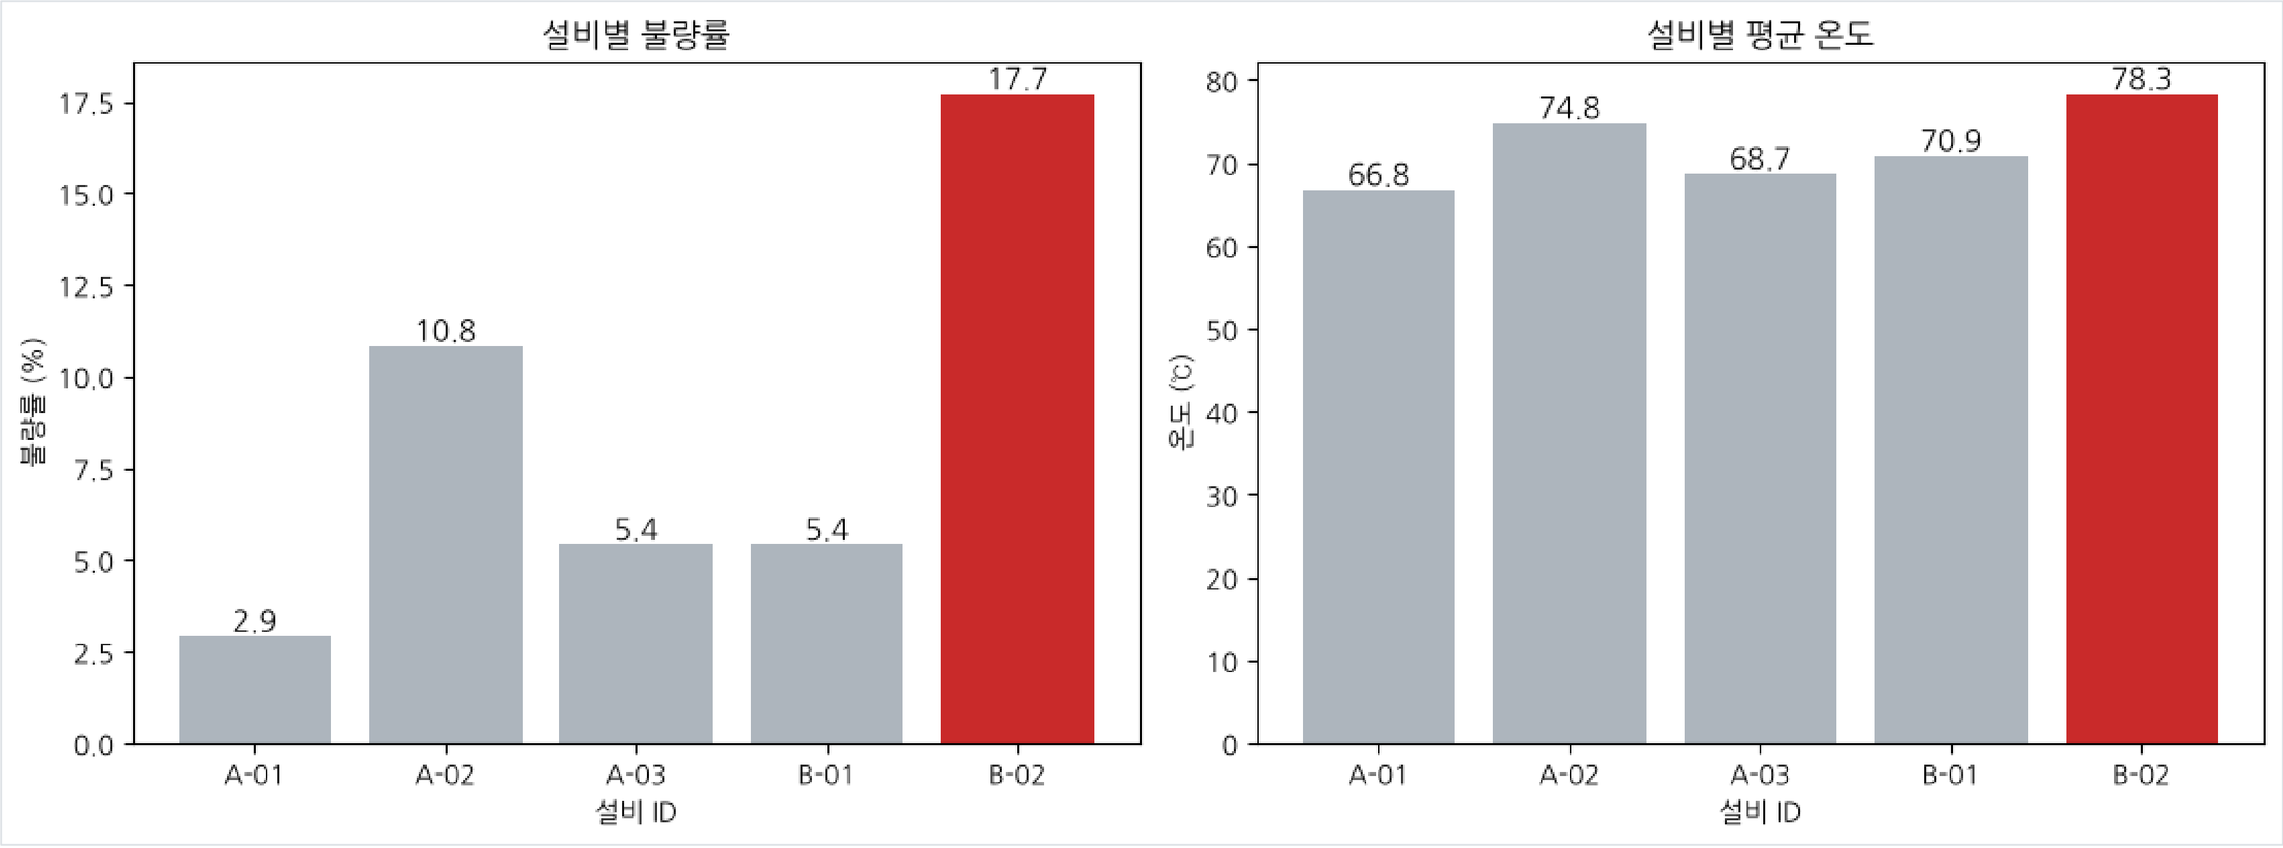
ChatGPT에게 이렇게 시키기

Colab에 올린 '라인_센서로그_가상데이터.csv' 파일을 읽어서 분석하는 파이썬 코드를 짜줘. 열은 일시, 설비 ID, 온도, 압력, 생산량, 불량여부(1=불량, 0=정상)야. 설비 ID별 불량률(%)과 평균 온도를 막대그래프 2개로 나란히 그려줘. 불량률이 가장 높은 설비는 빨간색, 나머지는 회색으로 하고 막대 위에 숫자를 써줘. 제목과 축 이름은 한글로.

빨간 막대가 B-02 (불량률 17.7%) 이면 성공

ChatGPT는 파일을 못 본다 → 열 이름만 보고 코드 작성 · 파일을 읽는 건 Colab | 대체 셀【미니②】

설비별 불량률 · 평균 온도 — 실행 결과



B-02 : 불량률 17.7% · 평균 온도 78.3℃ 모두 1위 → 온도가 원인일까? (3모듈 '상관과 인과'에서)

3

Python을 활용한 데이터 탐색 및 가공

EDA 기반 접근 · 공공데이터의 통계적 특징 · 결측값 처리와 가공 개념

탐색적 데이터 분석(EDA)

결론을 내기 전에, 데이터와 먼저 인사하는 단계



얼마나 있나?

행 · 열의 개수



어떻게 생겼나?

값의 범위 · 분포



이상한 곳은?

빈 값 · 튀는 값

비유: 새 라인에 투입되기 전, 설비를 한 바퀴 둘러보는 것

질문을 정하면 볼 데이터가 정해진다

질문

불량이 많은 시간대는?

필요한 열

일시 · 불량여부

분석 방법

시간대별 불량률 비교

✕

"이 데이터 분석해줘"

AI가 아무 분석이나 나열

○

"시간대별 불량률을 비교해줘"

필요한 분석만 정확하게

데이터를 받으면 이 7가지부터

① 크기
몇 행 · 몇 열?

```
df.shape
```

② 앞부분
제대로 읽혔나?

```
df.head()
```

③ 열 · 자료형
숫자가 숫자인가?

```
df.info()
```

④ 빈 값
빈 칸은 몇 개?

```
df.isnull().sum()
```

⑤ 요약통계
평균 · 최소 · 최대는?

```
df.describe()
```

⑥ 범주별 건수
어떤 값이 몇 번?

```
df["설비ID"]
.value_counts()
```

⑦ 분포
값이 어떻게 퍼져 있나?

```
df["온도"].hist()
```

심화 df.corr(numeric_only=True) 숫자 열끼리 함께 움직이는지 (상관 ≠ 원인)

describe() 결과, 이렇게 읽습니다

항목	뜻	a검사값	c검사값
count	값이 있는 개수	648	648
mean	평균	6.10	35.35
std	흩어진 정도 (산포)	0.17	0.89
min	최솟값	**5.70**	33.30
25%	아래에서 1/4 지점	6.00	34.70
50%	중앙값 (가운데 값)	6.10	35.40
75%	아래에서 3/4 지점	6.20	36.00
max	최댓값	6.60	37.40

※ 실습 파일 '라인생산 검사값' 실제 결과 · a검사값 규격 5.8~6.8

읽는 순서:
count (빠진 값이 있는가?) → min · max (규격 · 상식 범위안에 있는가?) → mean vs 50% (치우쳤는가?)

3-5 AI에게 EDA 시키기

코드는 AI가, 결과 읽기는 내가

프롬프트 예시

"A라인_센서로그.csv에 대해 EDA 체크리스트 7가지를 실행하는 pandas 코드를 짜 주고,
결과를 볼 때 무엇을 확인해야 하는지도 알려줘."

결과를 읽는 3가지 포인트

describe()

최소 · 최대가 상식 범위인가?

온도 최솟값 -999
→ 오류 코드일 수 있음

isnull().sum()

빈 값이 몰린 열은?

온도 결측이 많다
→ 센서 점검 기간?

value_counts()

같은 것이 다르게 적혔나?

A-01 / A01 / a-01
→ 같은 설비, 다른 표기

3-6 공공데이터 주의

파일이 안 열리거나, 숫자가 계산되지 않을 때

한글이 깨져요

UnicodeDecodeError 또는 ÇÑ±Û

인코딩(글자 저장 방식)이
한글용(cp949)인 파일이 많기 때문

```
pd.read_csv("파일.csv",
encoding="cp949")
```

숫자가 계산이 안 돼요

생산량 "1,200" → 문자로 인식

쉼표 · 단위가 붙은 숫자는
문자열(str)로 읽히기 때문

AI에게 요청:
"쉼표를 빼고 숫자로 바꿔줘"

3-7 통계적 특징

공공데이터의 숫자, 그대로 믿어도 될까?

지역	근로자 수	사고 건수
A지역	100,000명	**500건**
B지역	10,000명	**100건**

건수만 보면 A지역이 훨씬 위험해 보입니다. 정말 그럴까요?

A지역 · 1,000명당 사고율

5.0건

500 ÷ 100,000 × 1,000

B지역 · 1,000명당 사고율

10.0건

100 ÷ 10,000 × 1,000

숫자를 계산하는 법보다, 숫자를 잘못 해석하지 않는 법

결측값: 'NaN'만 빈 값이 아니다

```
df.isnull().sum()
```

→ 열마다 빈 칸(NaN) 개수를 세어 줍니다

그런데 이런 표기도 '빈 값'일 수 있습니다

NaN	-	없음	미상	N/A	0

생산량 0
→ 생산하지 않았다

생산량 (빈칸)
→ 조사 · 기록하지 않았다

0과 결측값은 다르다 → 데이터 설명서와 업무 기준으로 구분

3-9 확인 퀴즈

센서 온도가 비어 있습니다. 어떻게 할까요?

A라인 B-01 설비 · 11:00 기록
온도 = (빈칸) 압력 = 1.1 생산량 = 0

① 이 행을 삭제한다

② 온도 평균으로 채운다

③ 0℃로 채운다

④ 설비 상태와 데이터 정의서를 먼저 확인한다

힌트: 같은 시간의 생산량을 보세요

3-10 통계적 특징 ② 이상치

이상치: 튀는 값 하나가 숫자를 흔든다



평균 · 중앙값 · 최솟값 · 최댓값을 함께 확인 → df.describe() 로 한 번에

지우기 전에 원인부터: 입력 실수일까, 실제로 특별한 달일까?

절대값과 비율: 분모가 다르면 건수로 비교하지 않는다

절대값 (개수)		비율
불량품 개수	≠	**생산량 대비 불량률 (%)**
사고 건수	≠	**근로자 1,000명당 사고율**
기업 수	≠	**전체 기업 중 제조기업 비율**

```
df["불량률"] = df["불량수"] / df["생산량"] * 100
```

분모가 다른 집단을 단순히 건수로 비교하면 안 된다

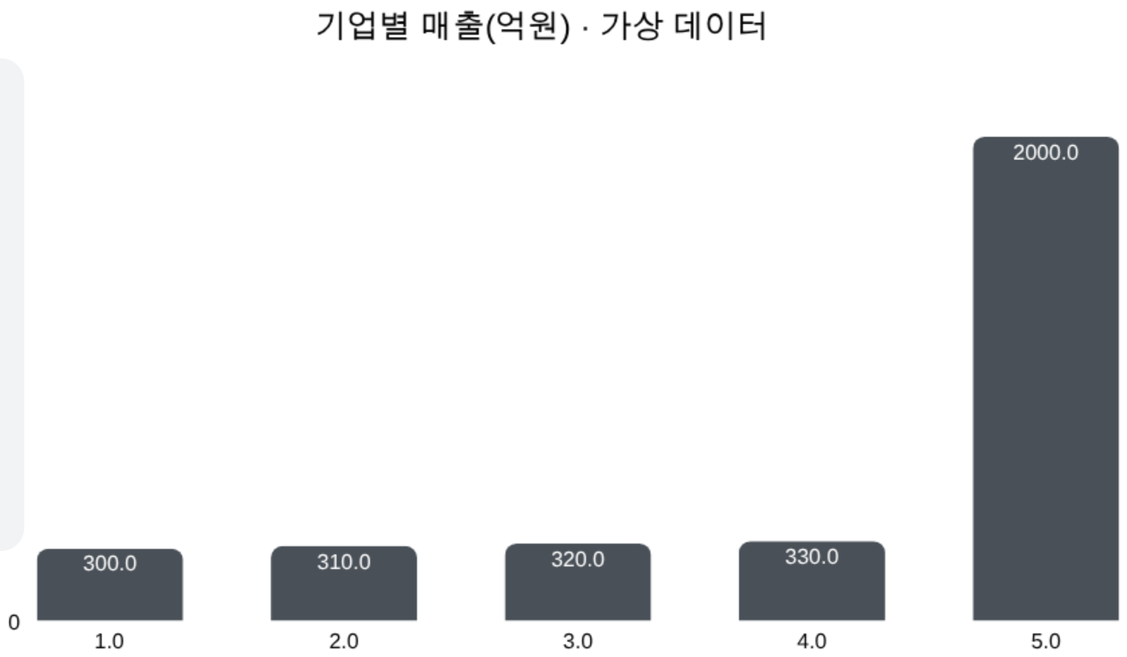
3-12 통계적 특징 ④ 평균의 함정

'평균 매출'은 보통 기업의 매출일까?

평균

652억

모두 더해
개수로 나눈 값



중앙값

320억

크기 순으로 줄 세웠을 때
가운데 값

평균소득 · 평균매출 · 평균생산량 → 중앙값과 분포도 함께 확인

3-13 통계적 특징 ⑤ 집계 기준과 단위

단위 · 지역 · 기간 기준이 같은가?

단위

금액 단위: 원 vs 천원
→ 1,000배 차이

지역 (집계 수준)

청주시 전체 vs
청주시 상당구 · 흥덕구
→ 합친 값과 나눈 값이 섞임

기간 기준

2024년 기준 · 말 기준
2024년 평균 · 누계
→ 모두 다른 숫자

분석 전에 단위 · 기간 · 지역 · 집계 기준을 데이터 설명서에서 확인

3-14 통계적 특징 ⑥ 상관과 인과

같이 움직인다고 원인은 아니다

분석 결과: **공장 규모가 클수록 산업재해 건수가 많았다**

✕ **"공장이 커지면 위험해진다"**

→ 큰 공장은 근로자 수도 많다 · 사람이 많으면 건수도 늘 수밖에

상관관계

두 값이 함께 움직인다

df.corr()로 확인 가능

인과관계

A 때문에 B가 생긴다

데이터만으로는 확인 불가 → 담당자 확인

상관 ≠ 원인 · 원인은 담당자가 따로 확인

3-15 통계적 특징 한눈에

공공데이터 6가지 함정, 한 장 정리

주제	핵심 질문	Python 연결
① 결측값	데이터가 없는 것인가, 0인가?	isnull()
② 이상치	유난히 크거나 작은 값이 있는가?	describe()
③ 절대값 · 비율	규모가 다른 집단을 건수로 비교하고 있지 않은가?	비율 계산
④ 평균의 함정	평균만 믿어도 되는가?	mean() · median()
⑤ 집계 기준 · 단위	단위와 기간 · 지역 기준이 같은가?	데이터 설명서 확인
⑥ 상관 · 인과	같이 움직인다고 원인인가?	corr() 정도

분석을 시작하면 일단 df.describe() 로 통계적 특징부터 살펴봅니다

빈 값을 처리하는 3가지 선택지



지우기

빈 값이 적고
특별한 이유가 없을 때

```
df.dropna()
```



채우기

평균 · 중앙값 · 직전 값 등으로
메울 수 있을 때

```
df.fillna(값)
```



그대로 두기

빈 값 자체가 의미일 때
(예: 설비 정지 기간)

```
# 처리하지 않음
```

어떤 방법을 고를지는 AI가 아니라, 업무를 아는 내가 판단합니다

코드는 맞아도 분석은 틀릴 수 있다

AI가 만든 코드

```
df = df.fillna(0)
```

AI 설명: "결측값을 0으로 처리했습니다" → 오류 없이 실행됨 ✓

온도 빈 값을 0℃로 바꿔도 될까요? → 모른다

0을 넣으면 온도 평균 71.2℃ → 53.4℃ (A라인 예시 데이터)

센서 통신 장애?

설비 정지?

실제로 0℃?

코드는 맞아도 분석은 틀릴 수 있다

원하는 행만 골라내기: 필터링

```
df[df["온도"] >= 80]
```

→ 온도가 80 이상인 행만 골라라

코드는 읽기만 · 작성은 AI에게

```
df[(df["온도"] >= 80) & (df["설비ID"] == "A-02")]
```

→ 온도가 80 이상이면서 설비가 A-02인 행

>=	==	&	|
크거나 같다	같다 (= 하나는 '담기')	그리고 (조건 모두)	또는 (조건 중 하나)

엑셀 기능과 비교하면 쉽다

그룹화 · 집계

≒ 피벗테이블

```
df.groupby("설비ID")["생산량"].sum()
```

변수 생성

≒ 새 열에 수식 넣기

```
df["시간대"] = df["일시"].dt.hour
```

병합 (이어붙이기)

≒ 여러 시트를 아래로 붙이기

```
pd.concat([df_3월, df_4월])
```

조인 (짝 맞추기)

≒ VLOOKUP

```
pd.merge(df, df_설비, on="설비ID")
```

코드는 읽기만 · 작성은 AI에게

실습 파일로 다시 보는 건수 · 합계 · 상식

① 건수

시트 9개 × 72행 = 648행
합친 뒤에도 648행인가?

② 합계

d검사값 합계 = 56,141
엑셀 SUM과 같은가?

③ 상식

a검사값 최솟값 5.7
규격(5.8~6.8) 밖 5건
→ 입력 오류? 실제 이탈?

※ 실습 파일 '라인생산 검사값' 실제 값

AI 코드를 실행한 뒤에는 항상: 건수 · 합계 · 상식

데이터 결측값 처리



실습 파일 확인 — Colab 📁 파일 패널

1

📁 파일 패널 열기

Colab 왼쪽
세로 메뉴의
📁 아이콘

→

2

파일 확인

2. 라인생산_ 검사값 대
온도_월별 Raw Data.xlsx
가 보이는지

→

3

없으면 다시 올리기

세션이 끊기면
파일이 사라짐
→ 끌어다 놓기

VS Code의 '폴더' = Colab의 '📁 파일 패널'

파일 이름이 다르면 read_excel("…") 안의 이름을 똑같이 맞춰야 합니다

1.Excel 데이터 불러오기


```
import pandas as pd

 #Excel 데이터를 Python으로 가져오는 명령
df = pd.read_excel("2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx")

 #데이터의 맨 위 5개 행을 화면에 보여달라는 명령
print(df.head())
```

```
                 구    분 Unnamed: 1     a검사값      b검사값   c검사값      d검사값  \
0                   NaN        NaN      NaN       NaN    NaN       NaN
1                  날짜         No.  5.8~6.8  3.0±1.0분  36±4℃  100±50mm
2  2019-03-07 00:00:00          1      6.2  03:05:00   35.7        84
3                   NaN          2      6.2  03:04:00   35.7        82
4                   NaN          3      6.2  03:07:00   35.9        84

         건조온도  Unnamed: 7  Unnamed: 8
0      1존 DEL      2존 DEL      3존 DEL
1  245 ± 50 ℃  245 ± 50 ℃  140 ± 30 ℃
2         244         245         134
3         245         245         134
4         244         245         134
```

2.데이터 구조 확인

한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

```
# 데이터가 몇 행 x 몇 열인가?
print(df.shape)

# 어떤 항목들이 있는가?
print(df.columns)
```

```
(74, 9)
Index(['구    분', 'Unnamed: 1', 'a검사값', 'b검사값', 'c검사값', 'd검사값', '건조온도',
       'Unnamed: 7', 'Unnamed: 8'],
      dtype='str')
```

3.결측치 확인

한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

```
print(df.isnull().sum())
```

```
구    분          70
Unnamed: 1      1
a검사값            1
b검사값            1
c검사값            1
d검사값            1
건조온도             0
Unnamed: 7      0
Unnamed: 8      0
dtype: int64
```

4.원본 Excel과 비교하기

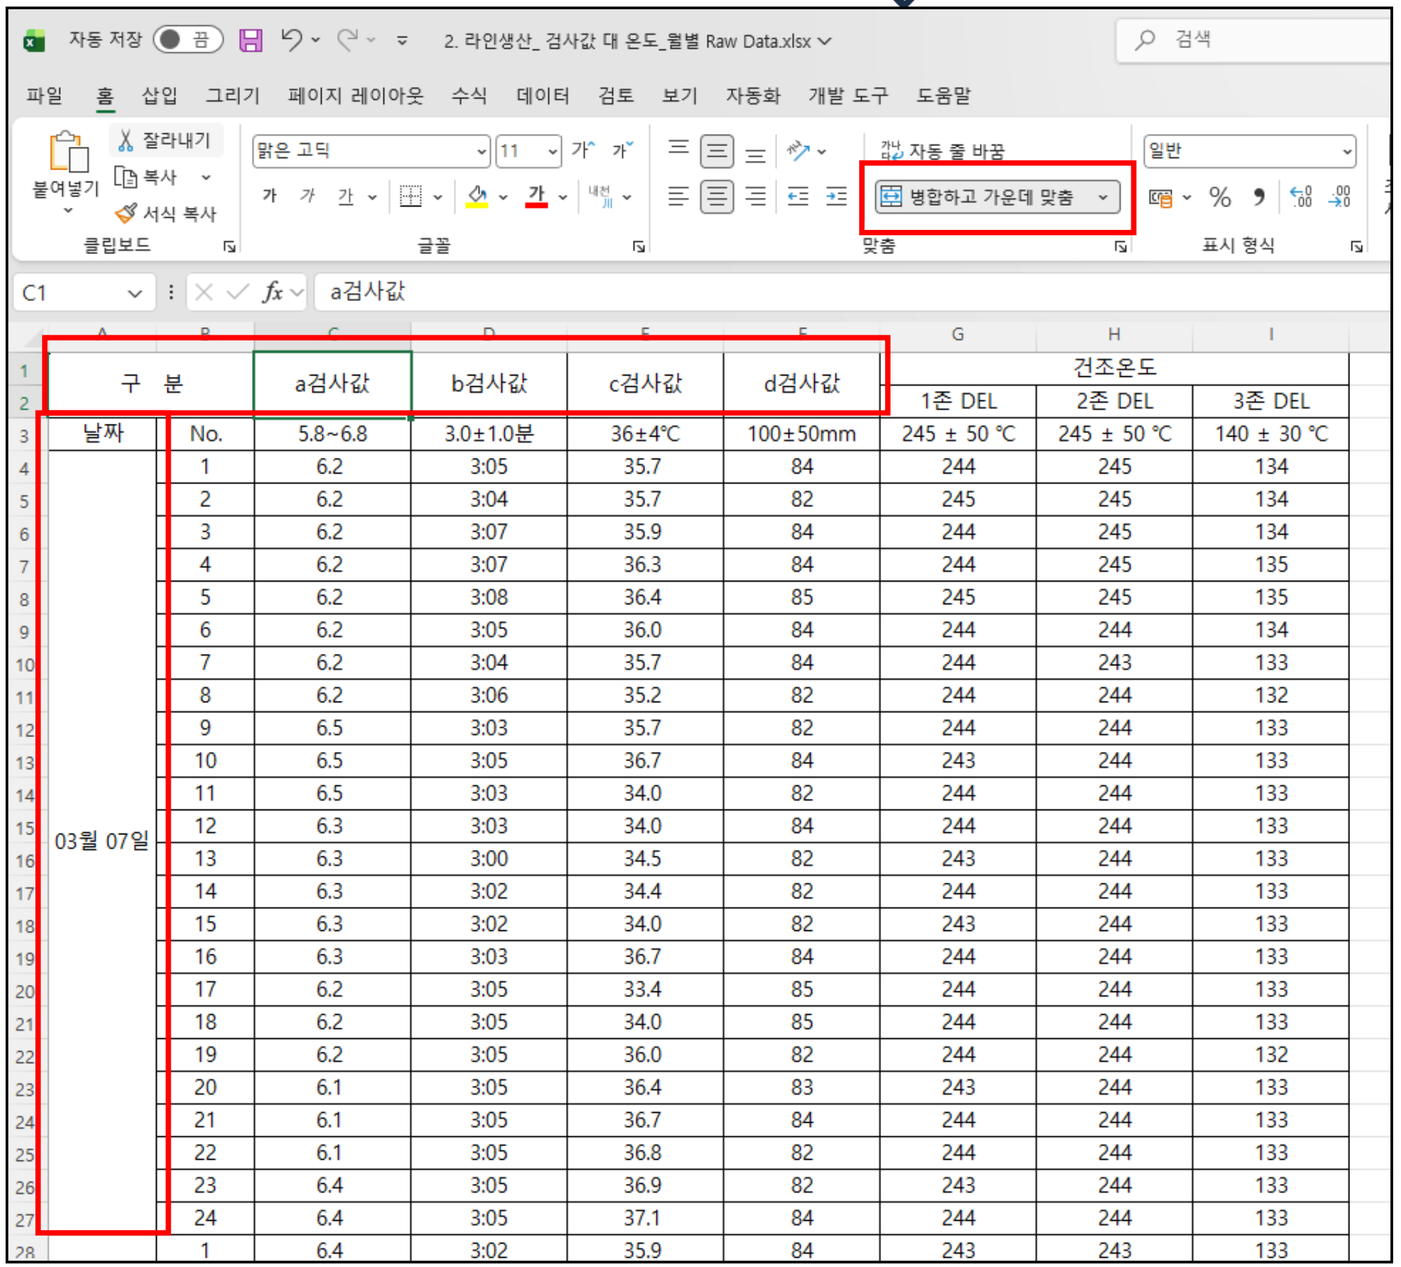
한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

```
                구  분 Unnamed: 1     a검사값      b검사값   c검사값      d검사값  \
0                 NaN        NaN      NaN       NaN    NaN       NaN
1                  날짜        No.  5.8~6.8  3.0±1.0분  36±4℃  100±50mm
2  2019-03-07 00:00:00          1      6.2  03:05:00   35.7        84
3                 NaN          2      6.2  03:04:00   35.7        82
4                 NaN          3      6.2  03:07:00   35.9        84

        건조온도  Unnamed: 7  Unnamed: 8
0      1존 DEL     2존 DEL     3존 DEL
1  245 ± 50 ℃  245 ± 50 ℃  140 ± 30 ℃
2          244         245         134
3          245         245         134
4          244         245         134
```

Colab에 'NaN'이라고 되어 있는 내용을 엑셀에서 확인하면 사람은 빈칸을 보고 위의 날짜와 같다고 이해하지만 pandas는 'NaN'값으로 받아들임

NaN이라고 해서 모두 데이터 오류는 아니다.



구 분		a검사값	b검사값	c검사값	d검사값	건조온도		
						1존 DEL	2존 DEL	3존 DEL
날짜	No.	5.8~6.8	3.0±1.0분	36±4℃	100±50mm	245 ± 50 ℃	245 ± 50 ℃	140 ± 30 ℃
03월 07일	1	6.2	3:05	35.7	84	244	245	134
	2	6.2	3:04	35.7	82	245	245	134
	3	6.2	3:07	35.9	84	244	245	134
	4	6.2	3:07	36.3	84	244	245	135
	5	6.2	3:08	36.4	85	245	245	135
	6	6.2	3:05	36.0	84	244	244	134
	7	6.2	3:04	35.7	84	244	243	133
	8	6.2	3:06	35.2	82	244	244	132
	9	6.5	3:03	35.7	82	244	244	133
	10	6.5	3:05	36.7	84	243	244	133
	11	6.5	3:03	34.0	82	244	244	133
	12	6.3	3:03	34.0	84	244	244	133
	13	6.3	3:00	34.5	82	243	244	133
	14	6.3	3:02	34.4	82	244	244	133
	15	6.3	3:02	34.0	82	243	244	133
	16	6.3	3:03	36.7	84	244	244	133
	17	6.2	3:05	33.4	85	244	244	133
	18	6.2	3:05	34.0	85	244	244	133
	19	6.2	3:05	36.0	82	244	244	132
	20	6.1	3:05	36.4	83	243	244	133
	21	6.1	3:05	36.7	84	244	244	133
	22	6.1	3:05	36.8	82	244	244	133
	23	6.4	3:05	36.9	82	243	244	133
	24	6.4	3:05	37.1	84	244	244	133
	1	6.4	3:02	35.9	84	243	243	133

5.날짜의 빈칸 채우기

#ffill forward fill, 즉 앞의 값으로 빈칸을 채운다는 의미

```
df['구분'] = df['구분'].ffill()
```

```
---------------------------------------------------------------------------
KeyError                                  Traceback (most recent call last)
File /usr/local/lib/python3.13/dist-packages/pandas/core/indexes/base.py:3641, in Index.get_loc(self, key)
   3640 try:
...
   3646     ):
   3647         raise InvalidIndexError(key) from err
-> 3648     raise KeyError(key) from err
   3649 except TypeError:
   3650     # If we have a listlike key, _check_indexing_error will raise
   3651     #  InvalidIndexError. Otherwise we fall through and re-raise
   3652     #  the TypeError.
   3653     self._check_indexing_error(key)
KeyError: '구분'
```

오류가 뜬다면, 생성형 AI에게 확인한다.
프롬프트는 복잡하지 않아도 됨
어떤 상황인지 설명 후 오류를 수정할 수 있는 파이썬 코드로 바꿔달라고 하면 됩니다.



이런 오류가 떠. 확인해줘.

Python 실행

```python
df['구분'] = df['구분'].ffill()
```

로 되어 있습니다.

그런데 실제 Excel의 열 이름은 `구분` **이 아니라** `구 분` **처럼 공백이 포함된 이름**입니다.

가장 확실하게 해결하는 방법

우선 `ffill()` 코드는 잠시 빼고 다음 코드만 실행해 보세요.

Python 실행

```python
print(df.columns.tolist())
```

그러면 실제 열 이름이 정확하게 출력됩니다. 예를 들어:

일반 텍스트

```
['구  분', 'Unnamed: 1', 'a검사값', 'b검사값',
 'c검사값', 'd검사값', '건조온도', 'Unnamed: 7', 'Unnamed: 8']
```

여기서 첫 번째 열 이름을 **그대로 복사**해서 사용하면 됩니다.

더 좋은 방법: 열 이름부터 변경

실습에서는 이렇게 하시는 것을 추천합니다.

Python 실행

```python
# 열 이름 확인
print(df.columns.tolist())

# 첫 번째 열 이름을 '구분'으로 변경
df.rename(columns={df.columns[0]: '구분'}, inplace=True)

# 변경됐는지 확인
print(df.columns.tolist())
```

정상적으로

일반 텍스트

```
['구분', 'Unnamed: 1', 'a검사값', ...]
```

가 나오면 그다음:

Python 실행

```python
df['구분'] = df['구분'].ffill()

print(df.isnull().sum())
```

을 실행합니다.

왜 `df.columns[0]`을 썼나요?

Python 실행

```python
df.columns[0]
```

은 **"첫 번째 열의 이름"**이라는 뜻입니다.

따라서 공백이 몇 개인지 일일이 세어서

```
# 열 이름 확인
print(df.columns.tolist())

# 첫 번째 열 이름을 '구분'으로 변경
df.rename(columns={df.columns[0]: '구분'}, inplace=True)

# 변경됐는지 확인
print(df.columns.tolist())

#ffill forward fill, 즉 앞의 값으로 빈칸을 채운다는 의미
df['구분'] = df['구분'].ffill()
```

```
['구    분', 'Unnamed: 1', 'a검사값', 'b검사값', 'c검사값', 'd검사값', '건조온도', 'Unnamed: 7', 'Unnamed: 8']
['구분', 'Unnamed: 1', 'a검사값', 'b검사값', 'c검사값', 'd검사값', '건조온도', 'Unnamed: 7', 'Unnamed: 8']
```

6.내용이 변경되었는지 확인

한국강사교육협회
KOREA INSTRUCTOR EDUCATION ASSOCIATION

#데이터의 맨 위 n개 행을 화면에 보여달라는 명령

```
print(df.head(10))
```

```
                  구분 Unnamed: 1     a검사값      b검사값   c검사값      d검사값  \
0                NaN        NaN      NaN       NaN    NaN       NaN
1                 날짜        No.  5.8~6.8  3.0±1.0분  36±4℃  100±50mm
2  2019-03-07 00:00:00          1      6.2  03:05:00   35.7        84
3  2019-03-07 00:00:00          2      6.2  03:04:00   35.7        82
4  2019-03-07 00:00:00          3      6.2  03:07:00   35.9        84
5  2019-03-07 00:00:00          4      6.2  03:07:00   36.3        84
6  2019-03-07 00:00:00          5      6.2  03:08:00   36.4        85
7  2019-03-07 00:00:00          6      6.2  03:05:00     36        84
8  2019-03-07 00:00:00          7      6.2  03:04:00   35.7        84
9  2019-03-07 00:00:00          8      6.2  03:06:00   35.2        82

         건조온도  Unnamed: 7  Unnamed: 8
0      1존 DEL      2존 DEL      3존 DEL
1  245 ± 50 ℃  245 ± 50 ℃  140 ± 30 ℃
2         244         245         134
3         245         245         134
4         244         245         134
5         244         245         135
6         245         245         135
7         244         244         134
8         244         243         133
9         244         244         132
```

7.엑셀 파일로 저장

Excel 원본
↓ read_excel()
Python의 df
↓ ffill()
수정된 df

까지 정리된 상태이므로, 원본 엑셀을 열어보면 변경 안 된 기존 상태임

df는 DataFrame으로 ‘Excel 데이터를 Python 작업공간으로 복사해 온 것’이라고 생각하면 됨

별도의 저장 명령이 필요

원본에 덮어쓰기보다는 새 파일로 저장하길 권합니다.

7.엑셀 파일로 저장

df.to_excel("전처리완료.xlsx", index=False)

[10]

```python
# 【3-⑦】 엑셀 파일로 저장 (원본에 덮어쓰지 않고 새 파일로)
df.to_excel("전처리완료.xlsx", index=False)

import os
print([f for f in os.listdir() if f.endswith('.xlsx')])   # 새 파일이 생겼는지 확인
```

```
['전처리완료.xlsx', '5. 공정데이터_MES_Tag Data.xlsx', '2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx']
```

Colab에서는 왼쪽 📁 파일 패널에 '전처리완료.xlsx'가 생깁니다 (안 보이면 🔄 새로고침)
파일 우클릭 → [다운로드] 또는 노트북의 내려받기 셀 실행 → 내 컴퓨터 '다운로드' 폴더

※ Colab 파일은 세션이 끝나면 사라지므로 바로 내려받으세요

전처리로 바뀐 것 2가지

① 열 이름 '구 분'(공백 3칸) → '구분' : 띄어쓰기까지 같아야 찾음 (KeyError 해결)
② 날짜 빈칸 70개 → 위 날짜로 채움 : 사람용 표 → 분석용 표 (한 행 = 한 기록)
※ 시트를 지정하지 않으면 첫 시트(3월)만 읽음 → 9개 시트 전체 · 머리글 정리는 4모듈 실습 ①에서

모두의 관심사 : 우리 팀 점심 데이터 분석

1

금요일엔 비싸게?

요일별
평균 점심값
→ 막대그래프

2

비 오면 국밥?

맑은 날 vs 비 오는 날
메뉴 비율
→ 묶은 막대

3

가성비 메뉴는?

메뉴별 가격 ×
만족도
→ 산점도

제조가 아니어도 같은 방법 → 묶기(groupby) · 비율(crosstab) · 그래프

가상 데이터 : 팀원 10명 × 2026년 9~10월 평일 40일 = 400건 (날짜 · 요일 · 날씨 · 메뉴 · 가격 · 만족도 · 대기시간)

점심 데이터 그래프 3개 주문하기

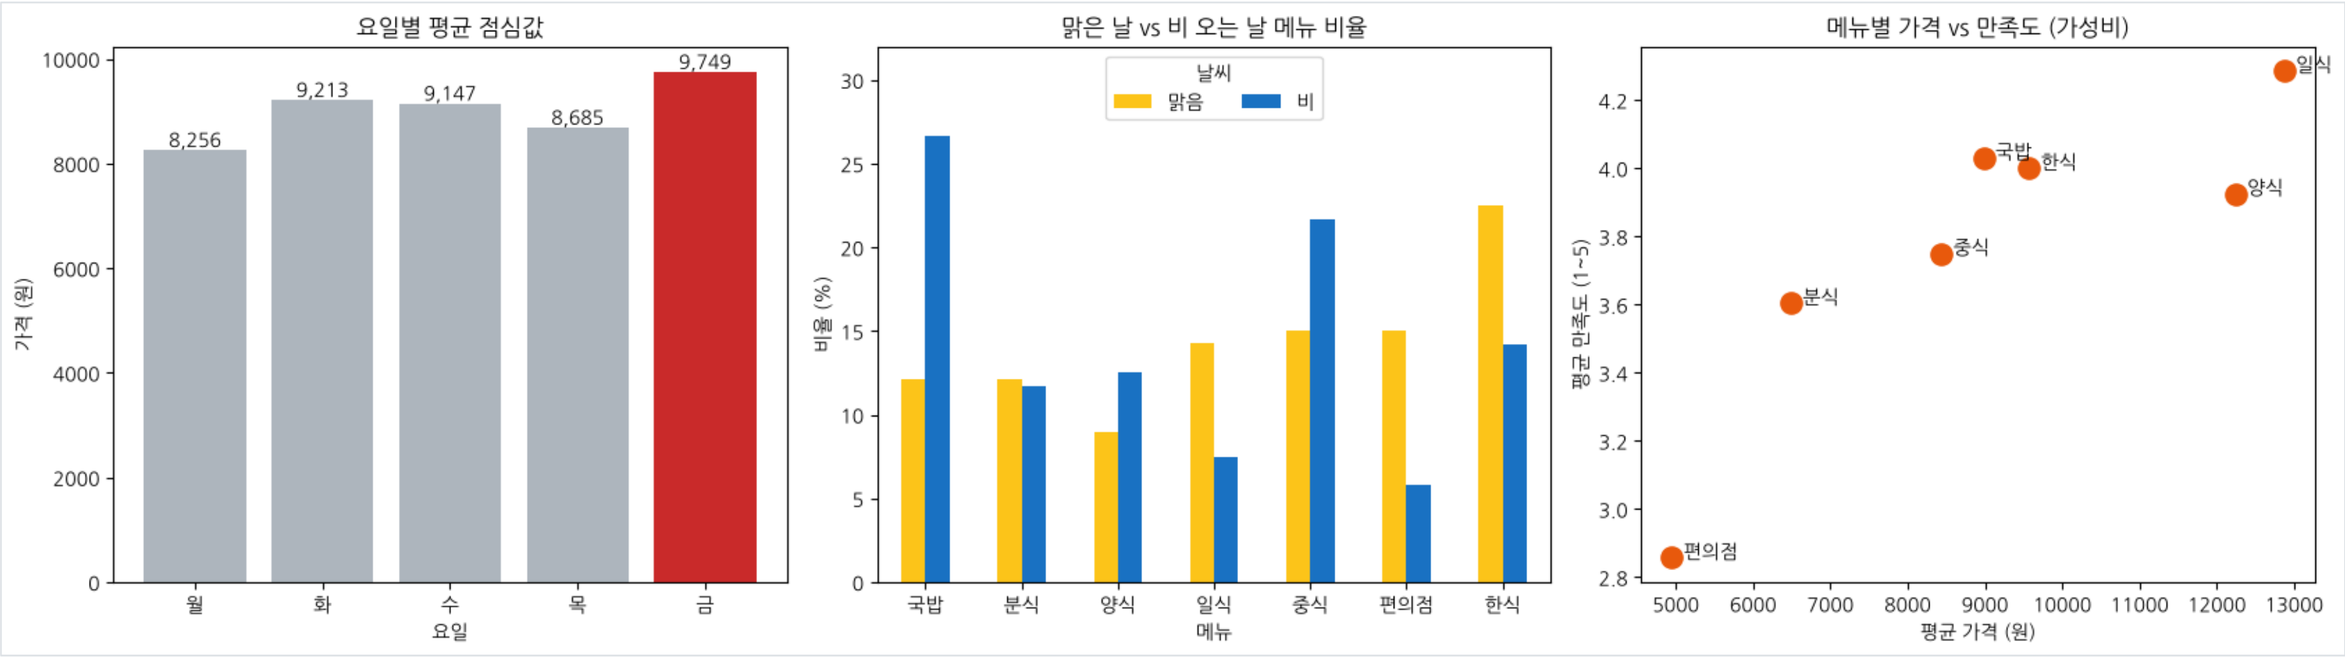
ChatGPT에게 이렇게 시키기

Colab에 올린 '우리팀_점심기록_가상데이터.csv'를 읽어서 분석하는 파이썬 코드를 짜줘. 열은 날짜, 요일, 날씨(맑음/비), 직원, 메뉴, 가격, 만족도(1~5), 대기시간(분)이야. 그래프 3개를 나란히 그려줘. ① 요일별 평균 점심값 막대그래프(월~금 순서, 가장 비싼 요일은 빨간색) ② 맑은 날과 비 오는 날의 메뉴별 비율(%) 비교 막대그래프 ③ 메뉴별 평균 가격(x)과 평균 만족도(y) 산점도, 점 옆에 메뉴 이름 표시. 제목과 축 이름은 한글로.

금요일 빨간 막대 · 비 오는 날 국밥이 가장 높으면 성공

노트북 대체 셀 : 【미니③】

우리 팀 점심 데이터 — 실행 결과



금요일 9,749원 최고 · 비 오는 날 국밥 12% → 27% · 가성비 1등은 국밥

점심 데이터도, 내 업무 데이터도 읽는 법은 같다

발견	점심 데이터	내 업무로 바꾸면
요일 패턴	금요일 점심값 최고	요일별 민원 · 문의 · 장애 건수
조건별 차이	비 오면 국밥 2배 이상	시즌별 · 고객 유형별 요청 차이
가성비	국밥 : 9,000원에 만족도 4.0	투입 시간 대비 성과 · 비용 대비 효과
주의	40일 · 10명뿐인 가상 데이터	표본이 작으면 '경향'까지만 말하기

'비 때문에 국밥'은 그럴듯한 가설 → 상관이지 인과는 아니다 (3-14)

4

Python을 활용한 데이터 분석

예측하기 · 판정하기 · 묶기 — 2번 파일(라인생산 검사값)로 실습

데이터 분석으로 할 수 있는 세 가지

1

예측하기 (회귀)

숫자로 숫자를 맞힌다

예) 1존 온도를 보고
2존 온도 맞히기

2

판정하기 (분류)

어느 쪽인지 고른다

예) 이 제품은
규격 안? 규격 밖?

3

묶기 (군집)

비슷한 것끼리 모은다

예) 평소와 다른
측정값 찾아내기

어려운 이름은 몰라도 됩니다 → '무엇을 알고 싶은가'만 정하면 AI가 코드를 씁니다

점심 뒤, Colab이 그대로인지 확인

1

파일 있나?

📁 패널에
엑셀 2개 · CSV
없으면 다시 올리기

→

2

폰트 셀

세션이 끊겼다면
【준비】 셀
다시 실행

→

3

4모듈 시작

노트북
'4모듈 · 데이터 분석'
【실습①】으로 이동

세션이 끊겨도 코드는 노트북에 그대로 → 파일만 다시 올리면 됩니다

시트 1개에서 9개 전체로

3모듈에서 한 것

2번 파일
시트 1개(72행)
불러오고 정리하기

→

지금 할 것

3월~11월
시트 9개를
한 표로 합치기

→

결과

648행짜리
하나의 표
(72행 × 9개월)

시트가 9개여도 시키는 말은 한 번 → 반복은 컴퓨터의 몫

9개 시트를 한 표로 합치기

ChatGPT에게 이렇게 시키기

'2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx' 파일에는 월별 시트가 9개 있어. 각 시트는 위 3줄이 머리글이고 4행부터 데이터야. 열은 날짜, 순번, a검사값, b검사값, c검사값, d검사값, 1존온도, 2존온도, 3존온도 순서야. 9개 시트를 하나의 표(df)로 합쳐 주고, 날짜 빈칸은 위 값으로 채워줘. 마지막에 행·열 개수를 보여줘. Google Colab용 파이썬 코드로, 한국어 주석을 달아줘.

이렇게 나오면 성공 : (648, 10) = 648행 · 10열

노트북 대체 셀 : 【실습①】

9개 시트 합치기 — 실행 결과

[11]

```
import pandas as pd, numpy as np, re, datetime as dt

FILE2 = '2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx'
sheets = pd.read_excel(FILE2, sheet_name=None, header=None, skiprows=3)   # 모든 시트를 한 번에

frames = []
for name, d in sheets.items():
    d.columns = ['날짜','순번','a검사값','b검사값','c검사값','d검사값','1존온도','2존온도','3존온도']
    d['월'] = int(name.split('월')[0])
    d['날짜'] = d['날짜'].ffill()
    frames.append(d)
df = pd.concat(frames, ignore_index=True)

def to_date(v):
    if isinstance(v, (dt.datetime, pd.Timestamp)):
        return pd.Timestamp(v)
    m = re.match(r'(\d+)월\s*(\d+)일', str(v))
    return pd.Timestamp(2019, int(m.group(1)), int(m.group(2)))

df['날짜'] = df['날짜'].map(to_date)
df['b검사값'] = df['b검사값'].map(lambda t: t.hour*60 + t.minute)   # 03:05:00 -> 185초
print(df.shape)
df.head()
```

```
(648, 10)
```

	날짜	순번	a검사값	b검사값	c검사값	d검사값	1존온도	2존온도	3존온도	월
0	2019-03-07	1	6.2	185	35.7	84	244	245	134	3
1	2019-03-07	2	6.2	184	35.7	82	245	245	134	3
2	2019-03-07	3	6.2	187	35.9	84	244	245	134	3
3	2019-03-07	4	6.2	187	36.3	84	244	245	135	3
4	2019-03-07	5	6.2	188	36.4	85	245	245	135	3

실행 결과 (648, 10) — 9개 시트가 648행 한 표로 합쳐짐

분석 후 무조건 확인하는 3가지

#

건수

9시트 × 72행
= 648행 맞나?

Σ

합계

d검사값 합계 56,141
엑셀 SUM과 같나?

!

상식

a검사값 규격 5.8~6.8
벗어난 값은 몇 건?

결과 : 648행 · 56,141 · 규격 밖 5건 → 숫자가 맞아야 다음 단계로

3가지 확인 — 실행 결과

[12]

```
print('건수:', len(df))
print('d검사값 합계:', df['d검사값'].sum())
print('빈 값:', int(df.isnull().sum().sum()))
print('측정 날짜 수:', df['날짜'].nunique(), '일')

# a검사값 규격 5.8~6.8
out_a = df[(df['a검사값'] < 5.8) | (df['a검사값'] > 6.8)]
print('a검사값 규격 이탈:', len(out_a), '건')
```

```
건수: 648
d검사값 합계: 56141
빈 값: 0
측정 날짜 수: 27 일
a검사값 규격 이탈: 5 건
```

건수 648 · d검사값 합계 56141 · 규격 이탈 5건

숫자로 숫자를 맞힌다

이럴 때 씁니다

1존 온도를 알면
2존 온도를 맞힐 수 있을까?

온도로 검사값을
미리 알 수 있을까?

결과는 딱 두 개만 보기

① 설명력 점수 (0~1)
1에 가까울수록 잘 맞음

② 평균 오차
평균적으로 얼마나 빗나가나

엑셀로 치면 : 산점도에 '추세선'을 긋고 R^2 값을 보는 것과 같습니다

설명력 점수 = 그냥 '평균'으로 찍을 때보다 얼마나 더 잘 맞히나

1

아무 정보 없이

2존 온도를 맞히라면?
→ 늘 '평균 245℃'로 찍기
= 기준 (0점)

→

2

1존 온도를 알면

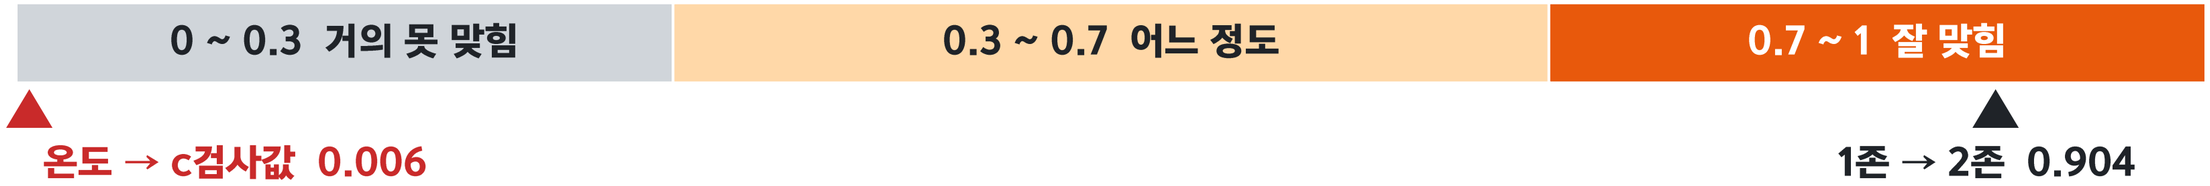
1존이 높은 날은
2존도 높게 예측
→ 빗나가는 정도가 줄어듦

→

3

얼마나 줄었나

평균으로 찍을 때보다
빗나감이 90% 줄면
→ 설명력 0.90



구간 기준은 이해를 돕는 대략적인 눈금입니다 (분야마다 다름) · 점수가 높아도 '원인'이라는 뜻은 아님

1존 온도로 2존 온도 맞히기

ChatGPT에게 이렇게 시키기

df에서 1존온도로 2존온도를 예측하는 선형회귀 모델을 만들어줘. 데이터의 80%로 학습하고 20%로 시험해줘(random_state=42). 결과는 '설명력 점수(R^2)'와 '평균 오차(RMSE)' 두 개만 출력하고, 1존 vs 2존 산점도도 그려줘. Google Colab용 코드, 한국어 주석.

성공 : 설명력 약 0.90 · 평균 오차 약 0.9℃

노트북 대체 셀 : 【실습③④】

1존 → 2존 예측 — 실행 결과

[13]

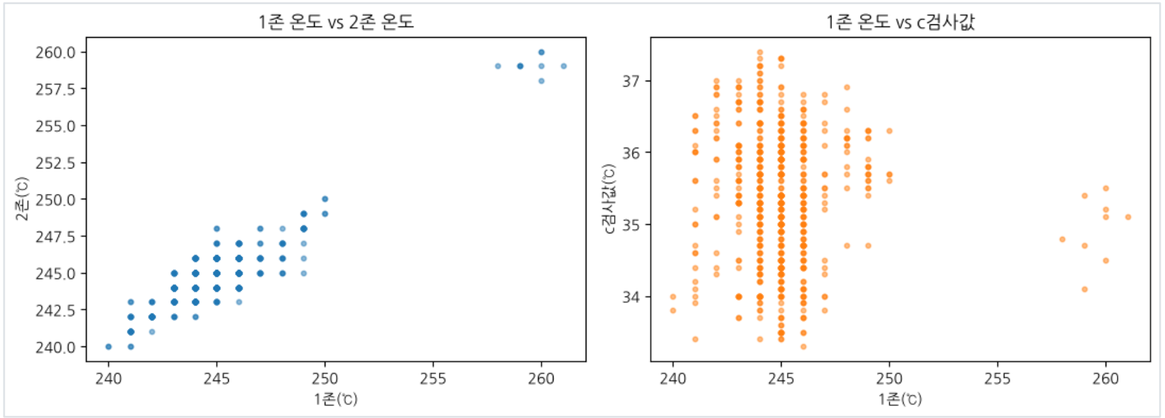
```python
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

def run_reg(X, y, label):
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
    model = LinearRegression().fit(X_train, y_train)
    pred = model.predict(X_test)
    rmse = np.sqrt(mean_squared_error(y_test, pred))
    base = np.sqrt(mean_squared_error(y_test, np.full(len(y_test), y_train.mean())))  # '평균으로 찍기'
    print(f'[{label}]  설명력 R²={r2_score(y_test, pred):.3f}  평균 오차 RMSE={rmse:.2f}  (평균으로 찍었을 때 RMSE={base:.2f})')
    return model

# 질문 A : 1존 -> 2존
model_A = run_reg(df[['1존온도']], df['2존온도'], '1존 → 2존 온도')
print('회귀식: 2존 =', round(model_A.coef_[0], 3), '× 1존 +', round(model_A.intercept_, 1))

# 질문 B : 건조온도 -> c검사값
model_B = run_reg(df[['1존온도','2존온도','3존온도']], df['c검사값'], '건조온도 → c검사값')
```

```
[1존 → 2존 온도]  설명력 R²=0.904  평균 오차 RMSE=0.91  (평균으로 찍었을 때 RMSE=2.95)
회귀식: 2존 = 0.84 × 1존 + 39.3
[건조온도 → c검사값]  설명력 R²=0.006  평균 오차 RMSE=0.85  (평균으로 찍었을 때 RMSE=0.86)
```



1존 → 2존 : 설명력 0.904 · 평균 오차 0.91℃ / 왼쪽 산점도 = 한 줄로 늘어섬

1존 온도로 2존 온도, 맞힐 수 있다

설명력 점수

0.90

100점 만점에 90점
2존 온도 변화의 90%를
1존 온도로 설명

평균 오차

0.9℃

예측하면 평균적으로
1℃도 안 틀림

한 줄 공식

2존 ≈ 0.84 × 1존 + 39.3

1존이 1℃ 오르면
2존은 약 0.84℃ 오름

산점도의 점들이 한 줄로 늘어서 있다 = 두 존은 함께 움직인다

온도로 c검사값도 맞힐 수 있을까?

ChatGPT에게 이렇게 시키기

같은 방법으로 1존·2존·3존 온도로 c검사값을 예측하는 선형회귀 모델을 만들어줘. 설명력 점수(R^2)와 평균 오차(RMSE)를 출력하고, 이 결과를 업무 담당자가 이해할 수 있게 한 문장으로 설명해줘.

결과 : 설명력 약 0.006 → 거의 0점

먼저 예상해 보세요 — O일까요, X일까요?

온도 → c검사값 — 실행 결과

[13]

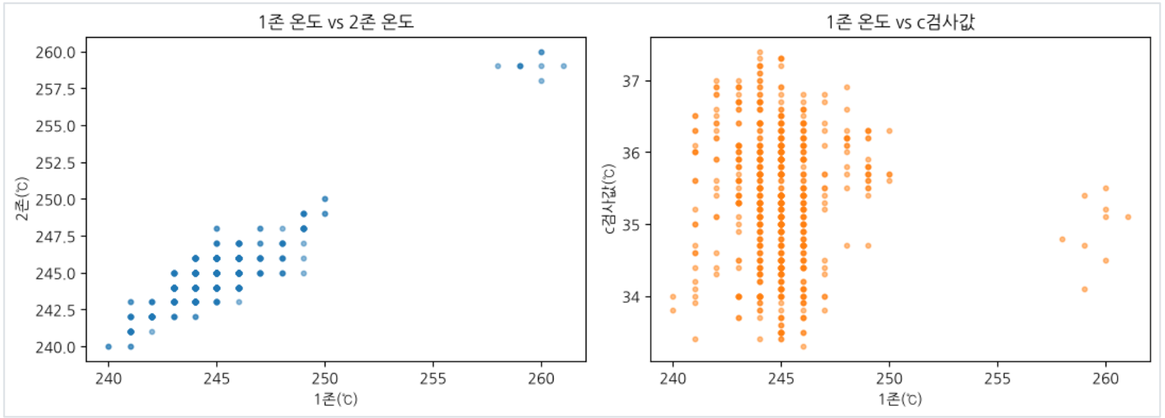
```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

def run_reg(X, y, label):
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
    model = LinearRegression().fit(X_train, y_train)
    pred = model.predict(X_test)
    rmse = np.sqrt(mean_squared_error(y_test, pred))
    base = np.sqrt(mean_squared_error(y_test, np.full(len(y_test), y_train.mean())))  # '평균으로 찍기'
    print(f'[{label}]  설명력 R²={r2_score(y_test, pred):.3f}  평균 오차 RMSE={rmse:.2f}  (평균으로 찍었을 때 RMSE={base:.2f})')
    return model

# 질문 A : 1존 -> 2존
model_A = run_reg(df[['1존온도']], df['2존온도'], '1존 → 2존 온도')
print('회귀식: 2존 =', round(model_A.coef_[0], 3), '× 1존 +', round(model_A.intercept_, 1))

# 질문 B : 건조온도 -> c검사값
model_B = run_reg(df[['1존온도','2존온도','3존온도']], df['c검사값'], '건조온도 → c검사값')
```

```
[1존 → 2존 온도]  설명력 R²=0.904  평균 오차 RMSE=0.91  (평균으로 찍었을 때 RMSE=2.95)
회귀식: 2존 = 0.84 × 1존 + 39.3
[건조온도 → c검사값]  설명력 R²=0.006  평균 오차 RMSE=0.85  (평균으로 찍었을 때 RMSE=0.86)
```



건조온도 → c검사값 : 설명력 0.006 / 오른쪽 산점도 = 흩어져 관계 없음

점수가 0점이면 실패일까?

아닙니다. '온도로는 c검사값을 맞힐 수 없다'는 것도 중요한 결과입니다

왜 이런 결과?

온도가 규격 안에서
안정적으로 관리되어
거의 변하지 않음
(1존 표준편차 약 2.4℃)

그럼 무엇을?

c검사값을 흔드는
다른 요인 찾기
(원료 · 설비 상태 등)

누가 판단?

AI는 '점수가 낮다'까지
해석과 다음 행동은
업무 담당자의 몫

'왜 이런 결과?'는 가설입니다 — 업무 담당자의 확인이 필요합니다

규격 안? 규격 밖? — 고르는 문제

이럴 때 씁니다

불량 / 정상 판정
설비 이상 / 정상
스팸 메일 / 정상 메일

꼭 필요한 것

정답표(라벨)
과거에 '불량'이었던
사례가 충분히 있어야

오늘 확인할 것

우리 데이터에
규격 밖 사례가
충분히 있을까?

모델 = 과거 데이터로 배운 규칙 → 새 데이터를 넣으면 답(숫자 · 판정)을 내주는 계산기

예) 실습 ③의 '2존 ≈ 0.84 × 1존 + 39.3'도 모델 · 판정 모델은 숫자 대신 '규격 안 / 밖'을 답함

모델을 만들기 전에 → 만들 수 있는 데이터인지부터 확인

규격 밖 사례는 몇 건일까?

ChatGPT에게 이렇게 시키기

a검사값의 규격은 5.8~6.8이야. 규격을 벗어나면 1, 아니면 0인 '규격이탈' 열을 df에 만들어줘. 0과 1이 각각 몇 건인지, 그리고 '전부 정상'이라고 찍었을 때 정확도가 몇 %인지 계산해줘.

결과 : 정상 643건 · 규격 밖 5건 · '전부 정상' 정확도 99.2%

노트북 대체 셀 : 【실습⑤】

규격 이탈 라벨 — 실행 결과

[15]

```
# a검사값이 규격(5.8~6.8)을 벗어나면 1(이탈)
df['규격이탈'] = ((df['a검사값'] < 5.8) | (df['a검사값'] > 6.8)).astype(int)
print(df['규격이탈'].value_counts())
print('이탈 비율:', round(df['규격이탈'].mean()*100, 2), '%')
print('→ 전부 정상이라고 찍어도 정확도 =', round((1-df['규격이탈'].mean())*100, 1), '%')
```

```
규격이탈
0    643
1      5
Name: count, dtype: int64
이탈 비율: 0.77 %
→ 전부 정상이라고 찍어도 정확도 = 99.2 %
```

정상 643 · 규격 밖 5 · '전부 정상' 정확도 99.2%

이 데이터로 판정 모델을 만들어도 될까?

배울 사례가 없다

규격 밖 5건으로는
패턴을 배울 수 없음

정확도의 함정

99.2%여도
'전부 정상'이라고
찍은 것과 똑같음

업무에 맞는 답

모델 대신
규격 이탈 알림
(관리도)

만들지 않기로 판단하는 것도 데이터 분석이다

좋은 소식 : 불량이 거의 없는 안정적인 공정이라는 뜻이기도 합니다

데이터 탐정 : 648건 속 '수상한 측정값'을 찾아라

1

정답이 없다

어느 게 이상한지
아무도 알려주지 않음

→

2

AI가 묶는다

온도 패턴이 비슷한
측정값끼리 2그룹으로

→

3

사람이 수사한다

작은 그룹은
언제, 왜 생겼을까?

엑셀로 치면 : 비슷한 행끼리 같은 색으로 칠해 주는 기능

AI에게 묶어 달라고 하기

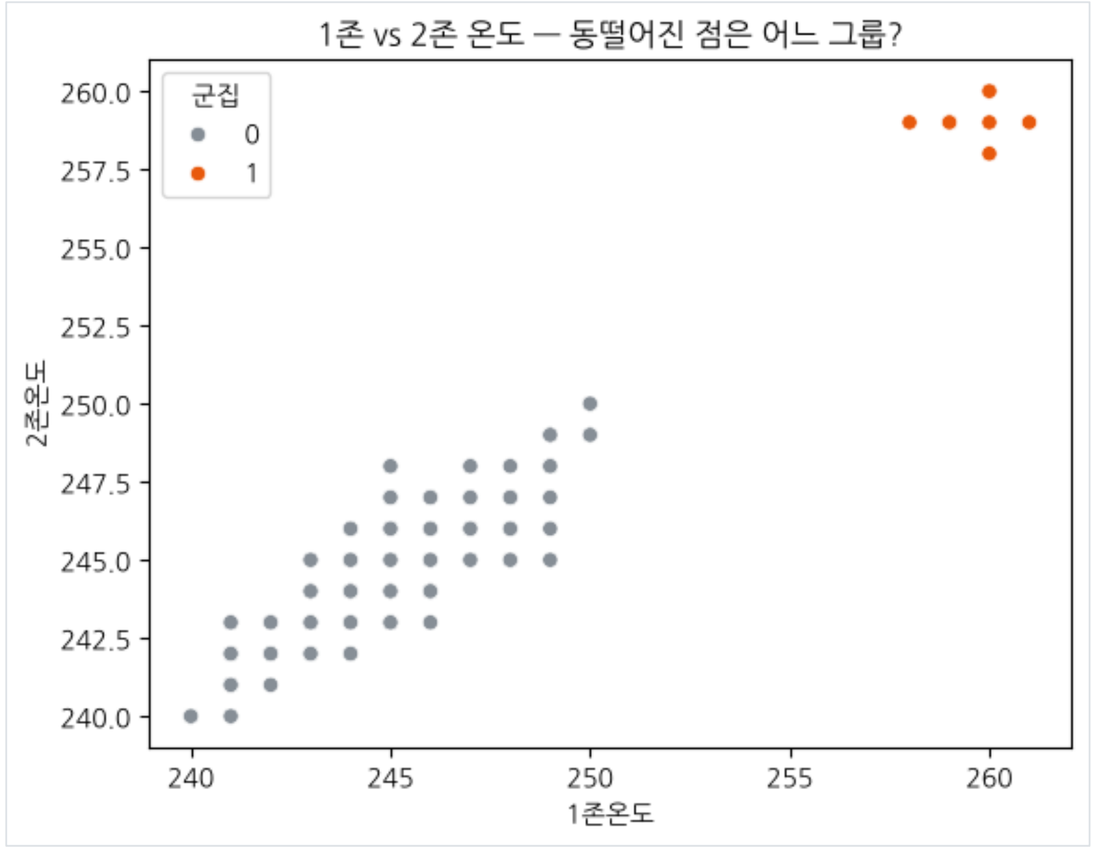
ChatGPT에게 이렇게 시키기

df의 1존온도, 2존온도, 3존온도로 측정값을 비슷한 것끼리 2개 그룹으로 묶어줘(KMeans, 표준화 후, random_state=42). 그룹별 개수와 평균 온도를 보여주고, 1존 vs 2존 산점도를 그룹별 색으로 그려줘. 마지막으로 개수가 적은 그룹의 날짜와 순번을 표로 보여줘.

결과 : 639건 vs 9건 → 9건은 모두 4월 10일

노트북 대체 셀 : 【실습⑥】

숨은 9건 — 실행 결과



[17]

```
# 작은 그룹은 누구인가? -> 현장 확인이 필요한 구간
small = df['군집'].value_counts().idxmin()
df[df['군집'] == small][['날짜','순번'] + feat + ['a검사값','c검사값']]
```

	날짜	순번	1존온도	2존온도	3존온도	a검사값	c검사값
73	2019-04-10	2	259	259	147	6.0	35.4
74	2019-04-10	3	259	259	145	5.9	34.7
75	2019-04-10	4	260	258	146	6.1	34.5
76	2019-04-10	5	260	260	146	6.1	35.5
77	2019-04-10	6	260	259	147	6.2	35.1
78	2019-04-10	7	258	259	147	6.4	34.8
79	2019-04-10	8	259	259	147	6.3	34.1
80	2019-04-10	9	260	260	146	6.3	35.2
81	2019-04-10	10	261	259	146	6.3	35.1

639건 vs 9건 → 주황 점 9개 → 모두 2019-04-10 순번 2~10

수상한 9건의 정체

그룹	1존	2존	3존	개수	언제?
평소	244.8	244.8	133.5	639건	3~11월 전체
수상한 그룹	259.6	259.1	146.3	9건	4/10 순번 2~10

확인 질문 ①

그날 설정 온도를
바꿨나?

확인 질문 ②

센서 오류는
아닌가?

확인 질문 ③

그 시간 제품 검사값은
규격 안이었나?

AI는 찾아주고 → 이유는 사람이 확인한다

모듈 4에서 한 것

예측하기

1존 → 2존 : 90점
온도 → c검사값 : 0점
'관계 없음'도 결과

판정하기

규격 밖 5건뿐
→ 모델 대신 알림
만들지 않는 판단

묶기

639건 vs 9건
4월 10일 고온 구간
담당자 확인 필요

질문 정하기 → AI에게 시키기 → 숫자 확인 → 업무 말로 해석

5

Python을 활용한 데이터 시각화

그래프 4종 릴레이 · ★ 한 줄 프롬프트로 공정 대시보드 만들기

목적이 그래프를 정한다

알고 싶은 것	그래프	오늘의 예
값이 어떻게 퍼져 있나 (분포)	히스토그램	a검사값 + 규격선
그룹별로 퍼진 모양 비교	박스플롯	월별 c검사값
크기 비교	막대그래프	월별 d검사값 평균
시간에 따른 변화 (추세)	선 그래프	측정일별 1존 온도

프롬프트에 항상 붙이기 : "제목과 축 이름(단위 포함)을 한글로 넣어줘"

그래프 4종 릴레이 — 하나씩 시켜 보기

① 분포

a검사값 분포를 히스토그램으로 그리고 규격 5.8과 6.8에 빨간 점선을 그어줘

② 분포 비교

월별 c검사값을 박스플롯으로 그려줘. 규격은 36±4℃야

③ 비교

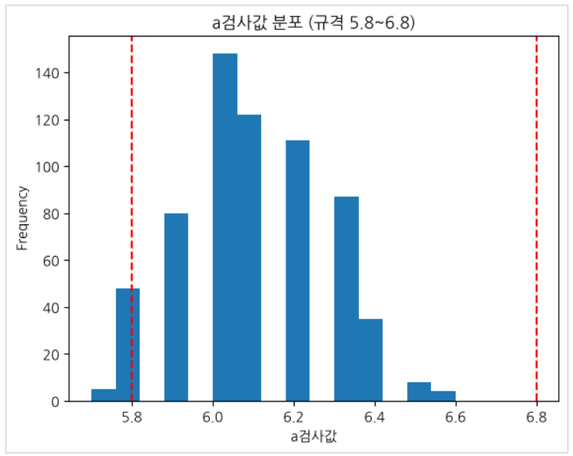
월별 d검사값 평균을 막대그래프로 그려줘

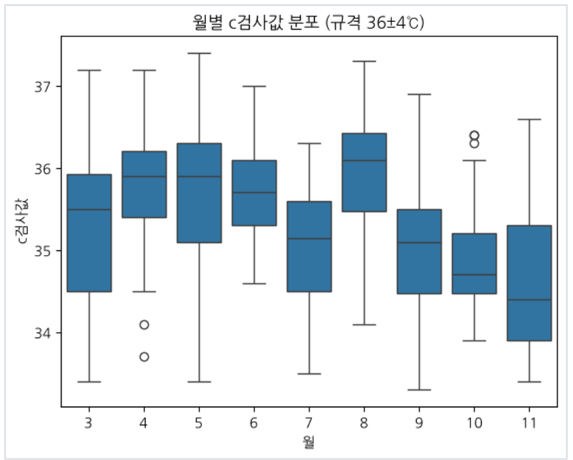
④ 추세

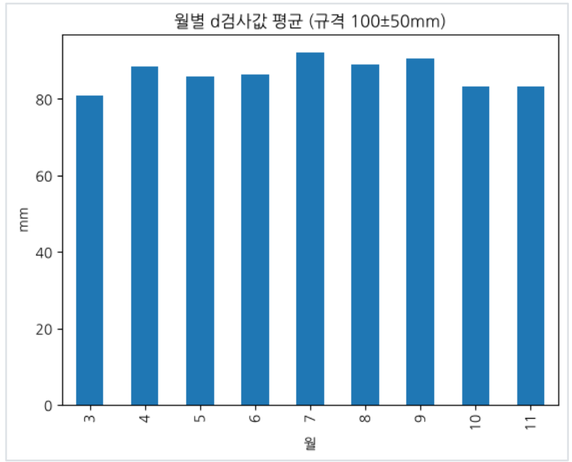
측정일별 1존 평균 온도를 점이 있는 선 그래프로 그려줘

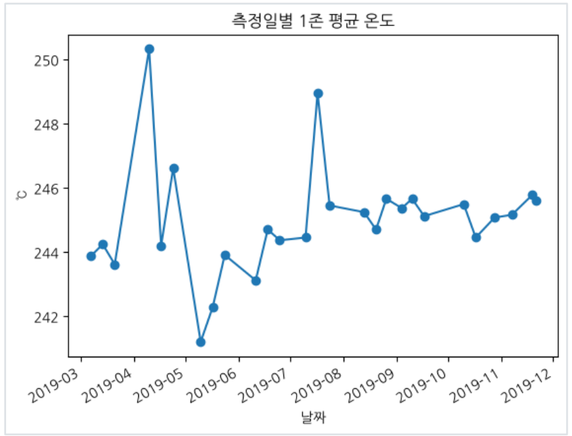
+ 모든 프롬프트 끝에 "제목과 축 이름을 한글로 넣어줘"

그래프 4종 — 실행 결과



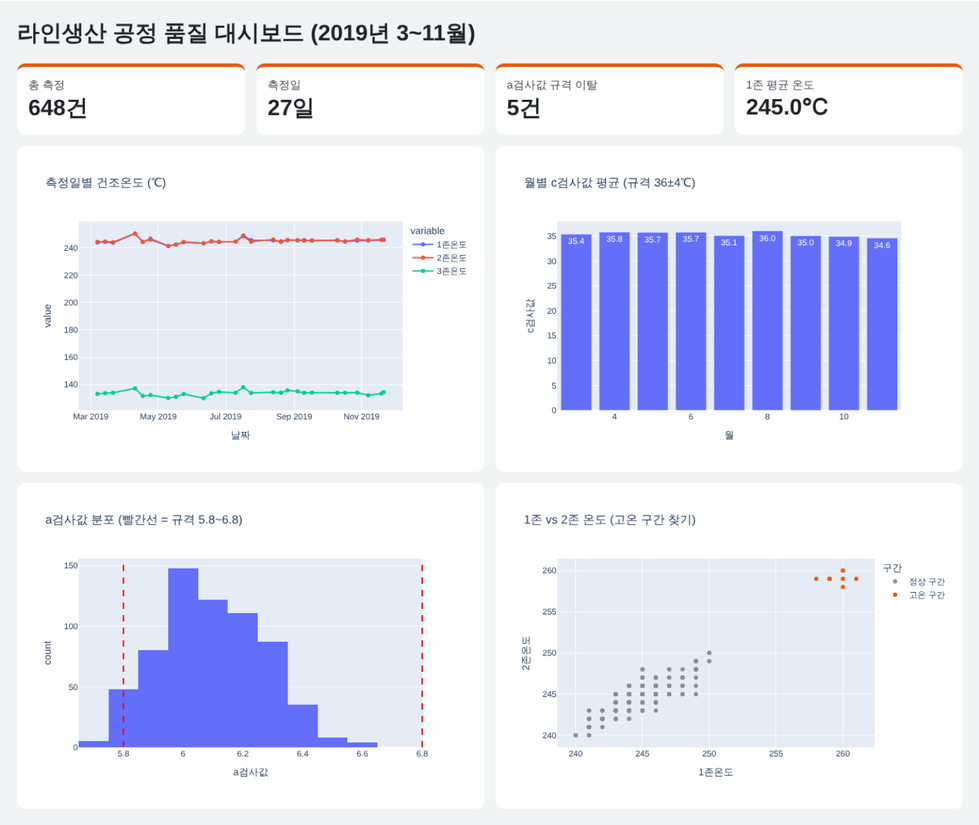






히스토그램 · 박스플롯 · 막대 · 선 그래프 (4월 10일 근처 튀는 점)

한 줄 프롬프트로 공정 품질 대시보드 만들기



실제 우리 데이터로 만든 결과

위 : 핵심 숫자 카드 4개
648건 · 27일 · 규격 밖 5건 · 245.0℃

아래 : 그래프 4개
마우스를 올리면 값이 보이고
드래그하면 확대됩니다

파일 하나(HTML)로 저장
→ 내려받아 메일로 보내면 누구나 열람

오른쪽 아래 그래프의 주황 점 9개 = 실습 ⑥의 '수상한 9건'

ChatGPT에게 대시보드 주문하기

ChatGPT에게 이렇게 시키기

df로 '라인생산 공정 품질 대시보드'를 HTML 파일 하나로 만들어줘(plotly 사용). 위에는 핵심 숫자 카드 4개(총 측정 건수, 측정일 수, a검사값 규격 5.8~6.8 이탈 건수, 1존 평균 온도), 아래에는 그래프 4개(측정일별 1·2·3존 온도 선 그래프, 월별 c검사값 평균 막대, a검사값 히스토그램에 규격선, 1존 vs 2존 산점도)를 2×2로 배치해줘. 주황색 포인트의 깔끔한 디자인, 파일 이름은 공정_대시보드.html. Google Colab용 코드.

카드 숫자가 648건 · 27일 · 5건 · 245.0℃ 와 같으면 성공

노트북 대체 셀 : 【실습⑧】

내가 만든 대시보드 — 실행 결과

[25]

```python
# 공정 품질 대시보드 만들기 (HTML 파일 1개 → 내려받아 브라우저로 열기)
import plotly.express as px

kpi = {
    '총 측정': f"{len(df):,}건",
    '측정일': f"{df['날짜'].nunique()}일",
    'a검사값 규격 이탈': f"{((df['a검사값'] < 5.8) | (df['a검사값'] > 6.8)).sum()}건",
    '1존 평균 온도': f"{df['1존온도'].mean():.1f}℃",
}
daily_t = df.groupby('날짜')[['1존온도','2존온도','3존온도']].mean().reset_index()
g1 = px.line(daily_t, x='날짜', y=['1존온도','2존온도','3존온도'], markers=True, title='측정일별 건조온도 (℃)')
monthly = df.groupby('월')['c검사값'].mean().reset_index()
g2 = px.bar(monthly, x='월', y='c검사값', title='월별 c검사값 평균 (규격 36±4℃)', text_auto='.1f')
g3 = px.histogram(df, x='a검사값', nbins=15, title='a검사값 분포 (빨간선 = 규격 5.8~6.8)')
g3.add_vline(x=5.8, line_color='red', line_dash='dash'); g3.add_vline(x=6.8, line_color='red', line_dash='dash')
df['구간'] = np.where(df['1존온도'] >= 252, '고온 구간', '정상 구간')
g4 = px.scatter(df, x='1존온도', y='2존온도', color='구간', title='1존 vs 2존 온도 (고온 구간 찾기)',
                color_discrete_map={'정상 구간':'#868E96', '고온 구간':'#E8590C'}, hover_data=['날짜','순번'])

cards = ''.join(f"<div class='card'><div class='k'>{k}</div><div class='v'>{v}</div></div>" for k, v in kpi.items())
charts = ''.join(f"<div class='box'>{g.to_html(full_html=False, include_plotlyjs=(i == 0))}</div>" for i, g in enumerate([g1, g2, g3, g4]))
html = f"""<html><head><meta charset='utf-8'><title>공정 품질 대시보드</title>
<style>body{{font-family:'Malgun Gothic',sans-serif;background:#F1F3F5;margin:24px}}
h1{{color:#1F2328}} .cards{{display:flex;gap:16px}} .card{{flex:1;background:white;border-radius:12px;padding:16px;border-top:5px solid
#E8590C}}
.k{{color:#495057}} .v{{font-size:32px;font-weight:bold;color:#1F2328}}
.grid{{display:grid;grid-template-columns:1fr 1fr;gap:16px;margin-top:16px}} .box{{background:white;border-radius:12px;padding:8px}}</style>
</head>
<body><h1>라인생산 공정 품질 대시보드 (2019년 3~11월)</h1><div class='cards'>{cards}</div><div class='grid'>{charts}</div></body></html>"""
with open('공정_대시보드.html', 'w', encoding='utf-8') as f:
    f.write(html)
print('공정_대시보드.html 저장 완료 → 왼쪽 📁 파일 패널에서 내려받아 더블클릭')
```

```
공정_대시보드.html 저장 완료 → 왼쪽 📁 파일 패널에서 내려받아 더블클릭
```



왼쪽 : 저장 완료 메시지 / 오른쪽 : 내려받아 브라우저로 연 공정_대시보드.html

멋진 화면도 숫자부터 확인

1

카드 숫자

648건 · 27일
5건 · 245.0℃
앞에서 구한 값과 같나?

2

그래프 제목·단위

℃ · 규격 표시가
빠지지 않았나?

3

산점도

주황 점 9개가
4월 10일 맞나?

예쁜 대시보드일수록 숫자가 틀리면 더 위험하다

같은 대시보드를, 이번엔 Colab 안에서 말로

	실습 ⑧ (ChatGPT → 복사)	실습 ⑧-2 (Colab 시각화 모드)
주문하는 곳	ChatGPT 대화창	Colab 안의 Gemini
코드 붙여넣기	직접 복사 → 셀에 붙여넣기	필요 없음 (자동 실행)
오류가 나면	오류를 복사해 "고쳐줘"	Gemini가 스스로 다시 시도
결과 공유	HTML 파일 내려받아 전달	전체 화면 링크 하나

둘 다 마지막은 같다 → 카드 숫자 648 · 27 · 5 · 245.0 확인

데이터가 Gemini(구글 AI)로 전달됩니다 · 업체 데이터 사용 허용을 먼저 확인

Colab 시각화 모드에 주문하기

Colab 시각화 모드에 이렇게 말하기

df로 라인생산 공정 품질 대시보드를 만들어줘. 위에는 숫자 카드 4개(총 측정 건수, 측정일 수, a검사값 규격 5.8~6.8 이탈 건수, 1존 평균 온도), 아래에는 측정일별 1·2·3존 온도 선 그래프와 1존 vs 2존 산점도를 배치해줘. 제목과 축 이름은 한글로.

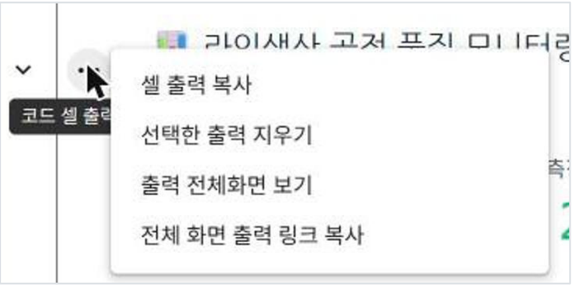
카드 숫자가 648건 · 27일 · 5건 · 245.0℃ 와 같으면 성공

Gemini 입력칸 ⚙ 아이콘 → 시각화 모드 → 붙여넣고 전송

시각화 모드 — 실제 실행 화면







① Gemini ☼ → 시각화 모드 · ② 카드 648 · 27 · 5 · 245.0 확인 · ③ 출력 메뉴 → 전체 화면 출력 링크 복사

MES 데이터 : 세로로 쌓인 표를 가로로

지금 모양 (세로)

한 줄 = 관 1개의
측정 1회
시간·관 이름·값이
아래로 계속 쌓임

→

바꿀 모양 (가로)

행 = 시간
열 = 관 #1~#5
= 엑셀 피벗테이블

→

그러면

관 5개 온도를
선 그래프 한 장에
겹쳐 그릴 수 있음

Colab에 올린 5번 엑셀의 '관 온도' 시트를 읽어서, 시간(EVENTTIME)을 행, 관 이름(RECIPEPARAMETERNAME)을 열로 하는 피벗 표로 바꾸고 관 5개의 온도를 선 그래프 한 장에 그리는 파이썬 코드를 짜줘.

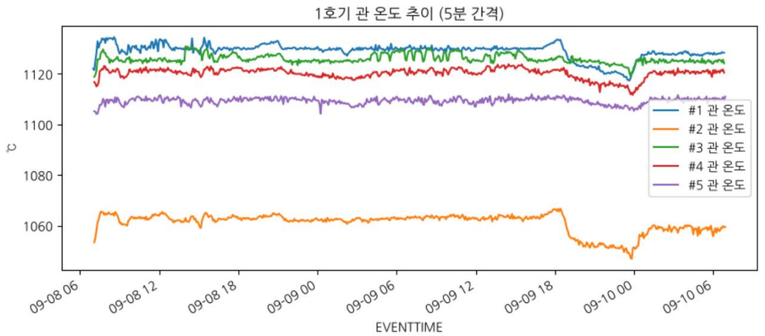
MES 관 온도 — 실행 결과

[26]

```
FILE5 = '5. 공정데이터_MES_Tag Data.xlsx'
mes = pd.read_excel(FILE5, sheet_name='관 온도')
mes['EVENTTIME'] = pd.to_datetime(mes['EVENTTIME'])

wide = mes.pivot_table(index='EVENTTIME', columns='RECIPEPARAMETERNAME', values='RESULTVALUE')
wide.columns = [c.replace('1호기_', '').replace('(측정값)', '') for c in wide.columns]
print(wide.shape)
wide.plot(figsize=(10, 4), title='1호기 관 온도 추이 (5분 간격)')
plt.ylabel('℃')
plt.show()
wide.describe().round(1)
```

(576, 5)



	#1 관 온도	#2 관 온도	#3 관 온도	#4 관 온도	#5 관 온도
count	575.0	575.0	574.0	574.0	575.0
mean	1129.0	1061.1	1126.0	1120.2	1109.3
std	3.0	3.8	1.8	2.1	1.3
min	1117.4	1046.8	1118.8	1111.7	1104.2
25%	1128.3	1060.0	1124.9	1119.4	1108.6
50%	1129.8	1062.5	1125.5	1120.7	1109.6
75%	1130.3	1063.3	1127.2	1121.6	1110.2
max	1134.6	1066.7	1130.9	1123.8	1112.0

관 온도 #1~#5 시계열 · 피벗 표 (576, 5)

6

프로젝트 실습

★ 코드 0줄 AI 대시보드 → 내 질문 1개로 미니 보고서 완성

코드 없이 : 엑셀 올리고 한 줄로 대시보드 받기

1

올리기 전 확인

회사 정책
개인정보
영업비밀
(2-5 보안 원칙)

→

2

엑셀 첨부

ChatGPT 대화창
+ 버튼으로
2번 엑셀 첨부

→

3

한 줄 주문

"이 파일로 공정 품질
대시보드를 만들어줘"

→

4

검증

카드 숫자가
648 · 27 · 5 · 245.0
와 같은지

파이썬으로 만든 대시보드(실습 ⑧)와 숫자가 같으면 → AI 결과를 믿을 근거가 생긴다

📎 **첨부 파일 : 2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx (업체 제공 · 실습 사용 허락 받음)**

엑셀 첨부 후 한 줄 주문

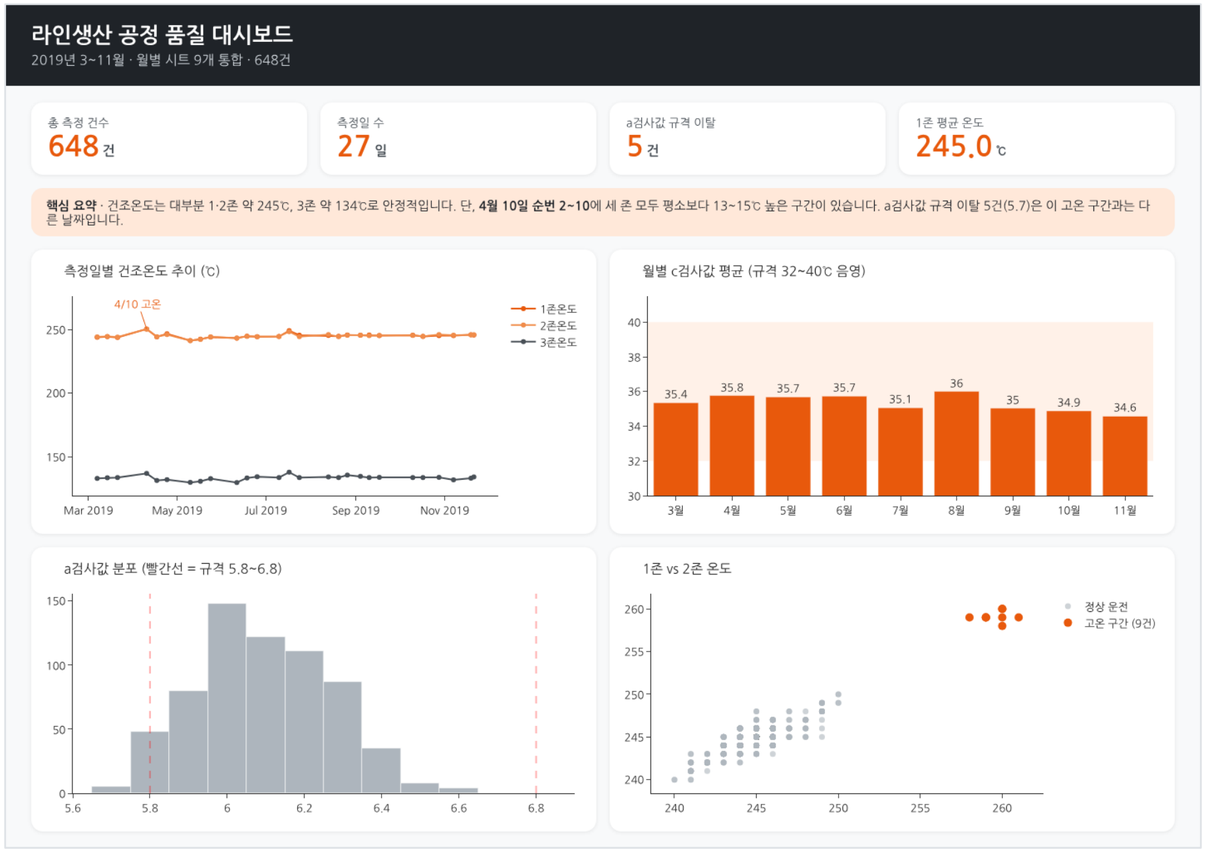
ChatGPT에게 이렇게 시키기

첨부한 엑셀은 라인생산 검사값과 건조온도 데이터야(월별 시트 9개, 각 시트 위 3줄은 머리글). 시트 9개를 합쳐서 '공정 품질 대시보드'를 만들어줘. 위에는 핵심 숫자 카드 4개(총 측정 건수, 측정일 수, a검사값 규격 5.8~6.8 이탈 건수, 1존 평균 온도), 아래에는 측정일별 건조온도 추이, 월별 c검사값 평균, a검사값 분포(규격선 표시), 1존 vs 2존 산점도. 주황색 포인트의 깔끔한 한국어 디자인으로, HTML 파일 하나로 만들어 내려받을 수 있게 해줘.

검증 : 카드 숫자 648 · 27 · 5 · 245.0℃

첨부 파일 : 2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx (업체 제공 · 사용 허락 받음)

AI 대시보드 — 결과 예시



같은 프롬프트로 만든 결과 예시 : 카드 648 · 27 · 5 · 245.0℃ → 실습 ⑧과 숫자 일치 (수업 화면은 ChatGPT 대화창)

AI 결과, 이 4가지만 확인하세요

확인	질문	오늘 데이터의 예
건수	행 수가 그대로인가?	9시트 합친 뒤에도 648행
합계	엑셀 SUM과 같은가?	d검사값 합계 56,141
상식	말이 되는 값인가?	a검사값 5.7 = 규격 밖 5건 → 입력 오류? 실제 이탈?
해석	숫자를 과장하지 않았나?	설명력 0.006 → '관계 없음'으로 정직하게

코드는 맞아도 분석은 틀릴 수 있다 → 그래서 확인한다

내 질문 1개로 미니 분석 보고서 만들기

1

데이터 고르기

A 업체 제공 파일
B 내 업무 데이터
C 공공데이터 CSV

→

2

질문 1개

예) 4월 10일 고온 구간의 검사값은 규격 안이었나?

→

3

그래프 2개

ChatGPT에게 시키고
제목·단위 확인

→

4

보고서 초안

ChatGPT가 공문서형으로
작성 → 내가 검증

'이 데이터 분석해줘' × → '시간대별 불량률을 비교해줘' ○

세 가지 길 — 내 업무에 가까운 것으로

길	이런 분께	질문 예시	주의
A 업체 제공 파일	제조 · 품질 업무	4월 10일 고온 구간의 검사값은 규격 안이었나? 관 온도 #1~#5 중 가장 흔들리는 관은?	노트북 예시 셀이 있어 막혀도 바로 실행 가능
B 내 업무 데이터	모든 분	월별 처리 건수는 어떻게 변했나? 업무 유형별 처리 시간은 얼마나 다른가?	회사 정책 먼저 확인 이름 · 연락처 · 고객사명은 지우거나 가명 처리
C 공공데이터 CSV	컨설팅 · 공공 · 학생	지역별 '인구 1,000명당' 비율로 비교하면? 연도별 추이는 어떻게 변했나?	data.go.kr에서 내려받기 한글이 깨지면 encoding='cp949'

B · C는 노트북 【실습⑫ B·C】 셀에서 파일 이름만 바꿔 불러온 뒤, 열 이름을 확인하고 프롬프트에 적습니다

막막하면 이 중 하나를 골라 괄호에 넣으세요

① 고온 구간 확인

2번 파일

"4월 10일 고온 구간의 a·c·d 검사값은 규격 안이었나?"

② 월별 추이

2번 파일

"월별 a검사값 평균은 어떻게 변했고, 가장 높은 달과 낮은 달은 언제인가?"

③ 규격 이탈 추적

2번 파일

"a검사값이 규격(5.8~6.8)을 벗어난 5건은 언제였고, 그때 1~3존 온도는 평소와 달랐나?"

④ 점심 데이터

점심 CSV · 모든 분야

"비 오는 날과 맑은 날, 점심 대기시간과 만족도는 얼마나 다른가?"

④를 고르면 프롬프트 첫 문장을 → "Colab에 올린 '우리팀_점심기록_가상데이터.csv'(열 : 날짜, 요일, 날씨, 직원, 메뉴, 가격, 만족도, 대기시간)를 읽어서"로 바꾸기

질문만 바꾸면 된다 → 다음 슬라이드 프롬프트의 '(여기에 내 질문)' 자리에 붙여넣기

내 질문으로 분석하기

ChatGPT에게 이렇게 시키기

df는 2번 파일 9개 시트를 합친 648행 표야(열 : 날짜, 순번, a~d검사값, 1~3존온도, 월). 내 질문은 '(여기에 내 질문)'이야. 이 질문에 답하는 결과 표 1개와 그래프 2개(제목·축 이름·단위 포함, 한글)를 만드는 Google Colab 코드를 한국어 주석과 함께 써줘.

(여기에 내 질문) ← 앞 슬라이드 ①~④ 중 하나를 그대로 붙여넣기

B · C 길(내 업무 · 공공데이터) : 'df는 …' 대신 '내 파일 my의 열은 ○○, ○○, ○○야'로 바꿔 요청

실행 결과 — 예시 질문 ① 고온 구간 확인

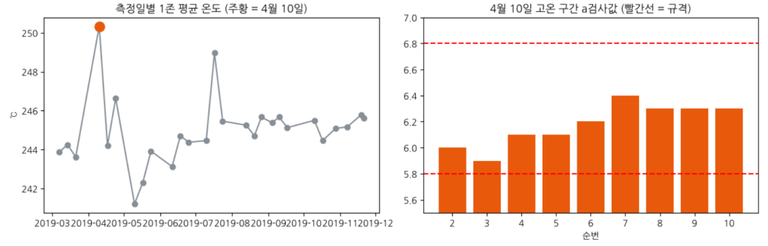
[27]

```
# 1) 고온 구간(1존 252℃ 이상)만 골라 검사값이 규격 안인지 판정
hot = df[df['1존온도'] >= 252][['날짜','순번','1존온도','a검사값','c검사값','d검사값']].copy()
hot['a 규격(5.8~6.8)'] = np.where(hot['a검사값'].between(5.8, 6.8), '안', '밖')
hot['c 규격(32~40)']  = np.where(hot['c검사값'].between(32, 40), '안', '밖')
hot['d 규격(50~150)'] = np.where(hot['d검사값'].between(50, 150), '안', '밖')
print('고온 구간:', len(hot), '건')
display(hot)

# 2) 그래프 2개 : 측정일별 1존 온도 / 고온 구간의 a검사값과 규격선
fig, ax = plt.subplots(1, 2, figsize=(12, 4))
t = df.groupby('날짜')['1존온도'].mean()
ax[0].plot(t.index, t.values, marker='o', color='#868E96')
ax[0].scatter([pd.Timestamp('2019-04-10')], [t.loc['2019-04-10']], s=120, color='#E8590C', zorder=3)
ax[0].set_title('측정일별 1존 평균 온도 (주황 = 4월 10일)'); ax[0].set_ylabel('℃')
ax[1].bar(hot['순번'].astype(str), hot['a검사값'], color='#E8590C')
ax[1].axhline(5.8, color='red', linestyle='--'); ax[1].axhline(6.8, color='red', linestyle='--')
ax[1].set_ylim(5.5, 7.0); ax[1].set_title('4월 10일 고온 구간 a검사값 (빨간선 = 규격)'); ax[1].set_xlabel('순번')
plt.tight_layout()
plt.show()
```

고온 구간: 9 건

	날짜	순번	1존온도	a검사값	c검사값	d검사값	a 규격(5.8~6.8)	c 규격(32~40)	d 규격(50~150)
73	2019-04-10	2	259	6.0	35.4	82	안	안	안
74	2019-04-10	3	259	5.9	34.7	85	안	안	안
75	2019-04-10	4	260	6.1	34.5	87	안	안	안
76	2019-04-10	5	260	6.1	35.5	90	안	안	안
77	2019-04-10	6	260	6.2	35.1	82	안	안	안
78	2019-04-10	7	258	6.4	34.8	89	안	안	안
79	2019-04-10	8	259	6.3	34.1	91	안	안	안
80	2019-04-10	9	260	6.3	35.2	88	안	안	안
81	2019-04-10	10	261	6.3	35.1	98	안	안	안



질문 ① "4월 10일 고온 구간의 a·c·d 검사값은 규격 안이었나?" → 고온 9건 모두 규격 '안'

의사결정 보고서 5칸

항목	쓸 내용	작성 팁
1. 목적	무엇을 알고 싶었나	내 질문 1문장
2. 데이터	파일 · 기간 · 건수	648행 · 2019년 3~11월
3. 결과	핵심 숫자 + 그래프	그래프에 제목·단위
4. 인사이트	알게 된 점 3가지 이내	숫자 근거와 함께
5. 제언	업무에서 할 일	'원인'이 아닌 '가설'로

분석 결과 : [Colab 결과 출력을 여기에 붙여넣기] → 이 결과로 '1. 목적 / 2. 데이터 / 3. 결과 / 4. 인사이트 / 5. 제언' 5칸 형식의 공문서형 보고서 초안을 표로 써줘. 숫자는 위 결과에 있는 것만 쓰고, 원인은 단정하지 말고 가설로 표현해줘.

양식 파일 : 의사결정보고서_5칸_양식.docx (빈 양식 · 작성 예시 · 복사용 프롬프트) · ChatGPT는 Colab 결과를 못 보니 숫자를 꼭 붙여넣기

보고서 초안 — 결과 예시

4월 10일 건조 공정 고온 구간 품질 영향 검토 (초안)

자료 : 2. 라인생산_ 검사값 대 온도_월별 Raw Data.xlsx

1. 목적

2019년 4월 10일 건조 공정에서 확인된 고온 운전 구간(순번 2~10)이 제품 검사값에 영향을 주었는지 확인하고자 함.

2. 데이터

월별 시트 9개(2019년 3~11월, 측정일 27일, 총 648건)를 통합하여 분석. 이 중 1존 온도 252℃ 이상인 고온 구간 9건을 대상으로 함.

3. 주요 결과

구분	1존 평균	2존 평균	3존 평균	건수
평상시 운전	244.8℃	244.8℃	133.5℃	639건
고온 구간 (4/10 순번 2~10)	259.6℃	259.1℃	146.3℃	9건

검사 항목	규격	고온 구간 측정 범위	판정
a검사값	5.8 ~ 6.8	5.9 ~ 6.4	9건 모두 규격 안
c검사값	36 ± 4℃ (32 ~ 40)	34.1 ~ 35.5	9건 모두 규격 안
d검사값	100 ± 50mm (50 ~ 150)	82 ~ 98	9건 모두 규격 안

4. 핵심 인사이트

1. 고온 구간 9건의 검사값은 모두 규격 안으로, 품질 영향은 확인되지 않음.
2. 세 존이 동시에 약 13~15℃ 높았던 점으로 보아, 설정값 변경 등 공정 조건 변화가 있었을 가능성이 있음(가설).
3. 같은 날 순번 1과 11~24는 평상시 온도 범위로, 일시적인 현상으로 보임.

5. 결론 및 제언

고온 구간에 따른 품질 이상은 확인되지 않았으나, 원인 확인을 위해 해당 시간대 설정값 변경 이력과 설비 로그 점검을 제안함. 아울러 1존 온도 기준(예 : 252℃ 이상) 알림을 두어 재발 시 즉시 확인할 수 있도록 검토가 필요함.

※ 위 원인은 데이터로 확인된 사실이 아닌 가설이며, 현장 확인이 필요함.

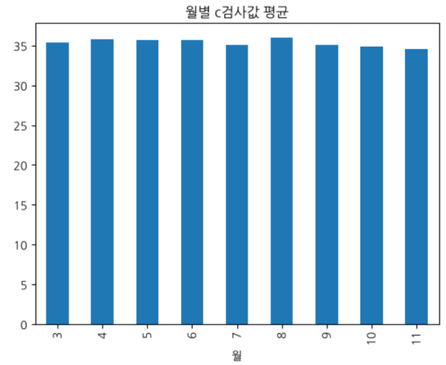
같은 프롬프트로 만든 결과 예시 : 5칸 공문서형 · 고온 구간 9건 모두 규격 안 · 원인은 '가설'로 표기

결과 파일 저장 — 실행 결과

[28]

```
# 표 저장 (엑셀)
summary = df.groupby('월').agg(
    a검사값평균=('a검사값','mean'), c검사값평균=('c검사값','mean'), d검사값평균=('d검사값','mean'),
    온도1존평균=('1존온도','mean'), 온도2존평균=('2존온도','mean'), 온도3존평균=('3존온도','mean')).round(2)
summary.to_excel('월별_검사값_요약.xlsx')

# 그래프 저장 (보고서/PPT용 고해상도)
ax = df.groupby('월')['c검사값'].mean().plot(kind='bar', title='월별 c검사값 평균')
plt.savefig('월별_c검사값.png', dpi=200, bbox_inches='tight')
plt.show()
summary
```



	a검사값평균	c검사값평균	d검사값평균	온도1존평균	온도2존평균	온도3존평균
월						
3	6.17	35.36	80.92	243.92	244.19	133.65
4	6.14	35.77	88.58	247.06	246.79	133.74
5	6.06	35.69	85.85	242.47	242.58	131.40
6	6.02	35.73	86.49	244.07	244.01	132.79
7	6.02	35.06	92.14	246.29	245.72	135.33
8	6.16	36.01	88.93	245.21	245.22	134.74
9	6.23	35.04	90.56	245.39	245.28	134.36
10	6.00	34.89	83.12	245.01	245.24	134.04
11	6.07	34.58	83.15	245.53	245.67	133.38

월별_검사값_요약.xlsx · 월별_c검사값.png 저장 → 내려받기 셀로 내 컴퓨터에

1분 발표 구조

1

질문

내가 던진 질문은
___ 입니다

2

데이터

데이터는 ___
(파일 · 건수)입니다

3

결과

그래프를 보면
___ 입니다

4

추가 확인

추가로 확인할 점은
___ 입니다

AI는 코드를 쓰고, 질문과 판단과 책임은 사람이 진다

정리

오늘 배운 것 — 시키고, 읽고, 검증하기

시킨다

질문 1개 + 데이터 설명
+ 원하는 결과 모양

읽는다

결과 숫자를
업무 말로 한 줄 해석

검증한다

건수 · 합계 · 상식
대시보드 숫자까지

코드는 맞아도 분석은 틀릴 수 있다 → 그래서 읽고, 검증한다


Q
A

Thank you

더 많은 AI 소식과 교육을 만나보세요.

한국강사교육협회 강의 의뢰/문의

NAVER 검색창

한국강사교육협회